论文推广 / A4-1

让AI去审批合同，结果如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

让AI去审批合同，结果如何?

Same Scores, Different Decisions

Fan Zhang、Yankai Chen、Zhuohan Xie 等

Jev 合同评测

123份合同
2,091项判断

模型调用费用低
也有持续错题

每道题
重复回答12次

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

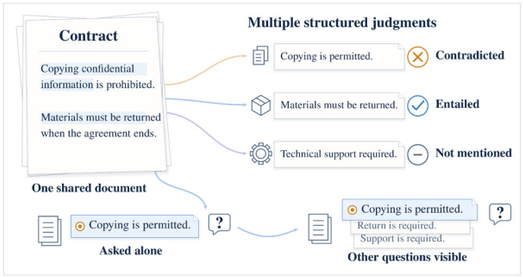

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文推荐 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

01 让AI去审批合同，结果如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI去审批合同，结果如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

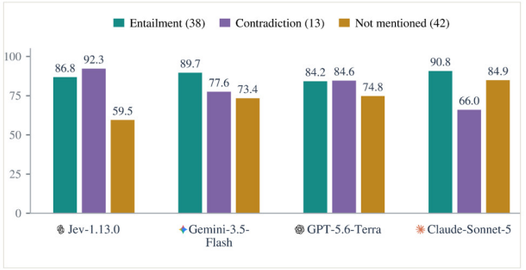

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1

让AI去审批合同，结果如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

相同分数背后的判断变化与持续错误

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

01 相同分数背后的判断变化与持续错误

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

相同分数背后的判断变化与持续错误

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

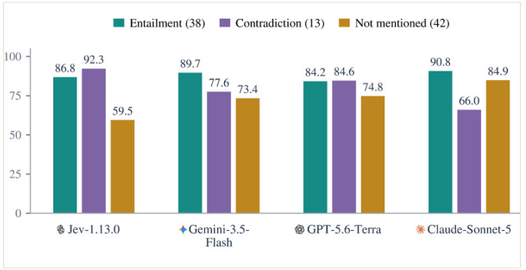

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

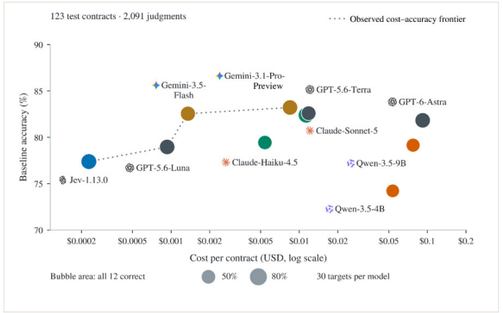

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-2

相同分数背后的判断变化与持续错误

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

Jev评测：题没变，AI却改了答案

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

Same Scores, Different Decisions

Jev评测：题没变，AI却改了答案

相同总分下，可能答错了不同的题。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

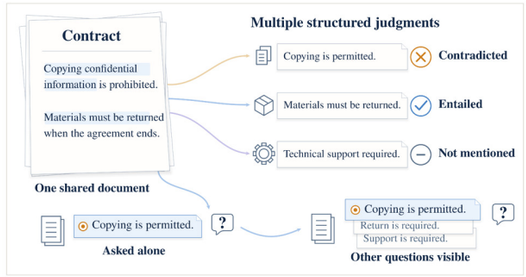

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

4次改对，4次改错，总分恰好没变

Qwen-3.5-4B在A/B两种安排的90组配对回答中，有9组答案不同：4组由错变对，4组由对变错，1组换成另一种错答案。

Model	Contrast	Valid pairs	Changed	Corrections	Regressions	Wrong-label changes	Net
Jev-1.13.0	A→B	90/90	4	4	0	0	+4
	B→C	90/90	1	0	1	0	−1
	C→D	90/90	0	0	0	0	0
Gemini-3.5-Flash	A→B	90/90	7	4	3	0	+1
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	6	1	5	0	−4
Gemini-3.1-Pro-Preview	A→B	89/90	7	3	4	0	−1
	B→C	90/90	7	4	3	0	+1
	C→D	90/90	3	0	3	0	−3
GPT-5.6-Luna	A→B	90/90	8	5	3	0	+2
	B→C	90/90	8	5	3	0	+2
	C→D	90/90	11	3	6	2	−3
GPT-5.6-Terra	A→B	90/90	7	6	0	1	+6
	B→C	90/90	7	3	3	1	0
	C→D	90/90	10	2	6	2	−4
GPT-6-Astra	A→B	90/90	4	1	3	0	−2
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	3	3	0	0	+3
Claude-Haiku-4.5	A→B	90/90	8	6	1	1	+5
	B→C	90/90	6	3	0	3	+3
	C→D	90/90	14	2	12	0	−10
Claude-Sonnet-5	A→B	90/90	5	3	2	0	+1
	B→C	90/90	6	5	1	0	+4
	C→D	90/90	3	1	0	2	+1
Qwen-3.5-4B	A→B	90/90	9	4	4	1	0
	B→C	88/90	9	7	1	1	+6
	C→D	87/90	14	5	8	1	−3
Qwen-3.5-9B	A→B	90/90	15	8	7	0	+1
	B→C	90/90	7	3	4	0	−1
	C→D	88/90	12	7	5	0	+2

相同的总分，可能对应不同的错题。

90组来自30道题各重复3次；9次变化涉及6道题。A/B分别为单独提问、展示17项但只回答目标题。

Table 10 · 首轮30题的配对回答 · 论文原图

AI 论文推荐 04 / 08

提问没变，答案也出现了变化

研究同时检查了两类变化：换一种提问安排后，答案是否改变；保持相同请求、重复调用时，答案是否改变。

	Across conditions			Identical-request repetition			
Model	A–B	B–C	C–D	A	B	C	D
Jev-1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini-3.5-Flash	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini-3.1-Pro-Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6-Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6-Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6-Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude-Haiku-4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude-Sonnet-5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen-3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen-3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

Qwen那6道变动的题，在相同请求下也变过。

因此，仅凭A/B之间的9次变化，还无法区分提问安排的影响与重复调用本身的波动。

Table 11 · 提问安排与重复调用 · 论文原图

01 Jev评测：题没变，AI却改了答案

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI却改了答案

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-3

Jev评测：题没变，AI却改了答案

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

让AI去审批合同，结果如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

让AI去审批合同，结果如何?

Same Scores, Different Decisions

Fan Zhang、Yankai Chen、Zhuohan Xie 等

123份合同

基础准确率
77.38%

Jev 调用费用
$0.000228
每份合同

合同内容判断 · 每次请求17项答案

arxiv.org/abs/2609.27678

01 让AI去审批合同，结果如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

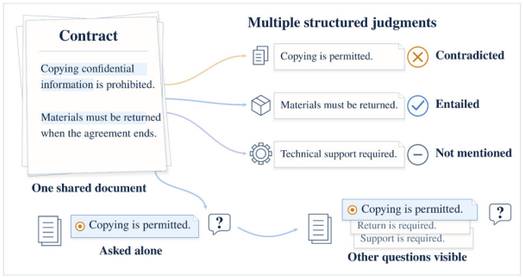

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

AI 论文推荐 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

AI 论文推荐 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI去审批合同，结果如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

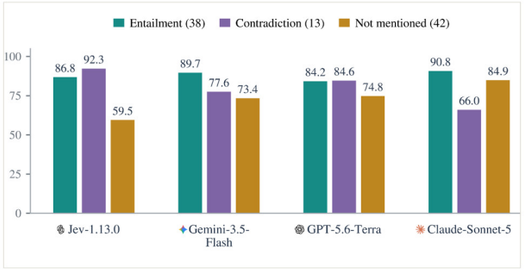

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-4

让AI去审批合同，结果如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

论文推广 / A4-5

Jev答题稳不稳？同一题测12次

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev答题稳不稳？

同一题测12次

Same Scores, Different Decisions

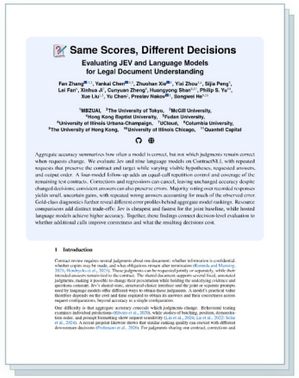

Table 4

模型	12次全对	始终同一错答
Jev-1.13.0	67/93	17
Gemini-3.5-Flash	66/93	11
GPT-5.6-Terra	64/93	8
Claude-Sonnet-5	70/93	6

arxiv.org/abs/2609.27678

01 Jev答题稳不稳？同一题测12次

论文首页 · Table 4 节选重排

高清原图 · 随本版下载包提供

AI 论文推荐 02 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

AI 论文推荐 03 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

AI 论文推荐 04 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

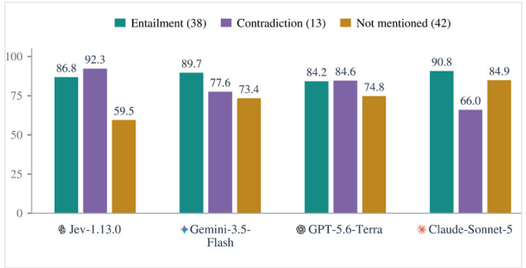

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

Jev答题稳不稳？同一题测12次

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响？

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题？

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响？

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题？

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-5

Jev答题稳不稳？同一题测12次

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

相同分数背后的判断变化与持续错误

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

相同分数背后的 判断变化 与 持续错误

Same Scores, Different Decisions

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

1 Introduction

平均分之外

哪些答案变了?
哪些题一直对?
哪些错一直留着?

Jev 与
9个语言模型

ContractNLI
合同判断任务

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

都问12次, 换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 03 / 08

平均分都约79%, 12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 04 / 08

93道题里, Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

01 相同分数背后的判断变化与持续错误

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

相同分数背后的判断变化与持续错误

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

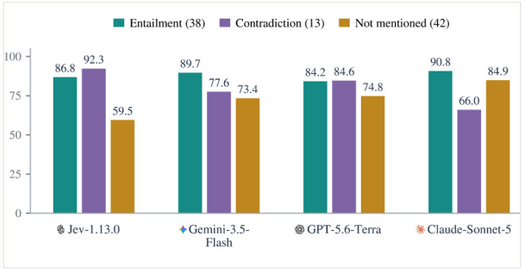

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

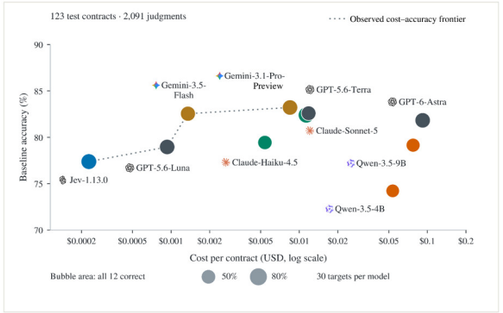

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-6

相同分数背后的判断变化与持续错误

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

Jev答题稳不稳？同一题测12次

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev答题稳不稳？

同一题测12次

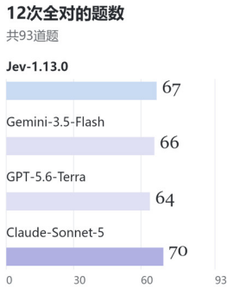

Table 4

模型	答案始终一致	始终同一错答
Jev-1.13.0	84/93	17

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 03 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 04 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

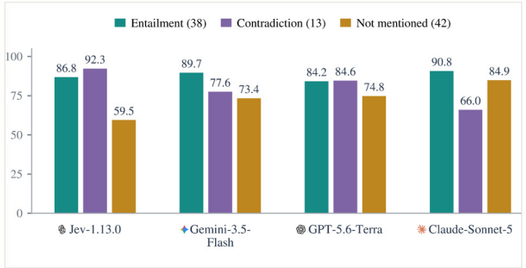

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

01 Jev答题稳不稳？同一题测12次

论文首页 · 据 Table 4 绘制

高清原图 · 随本版下载包提供

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

Jev答题稳不稳？同一题测12次

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响？

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题？

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响？

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题？

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-7

Jev答题稳不稳？同一题测12次

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

Jev评测：题没变，AI却改了答案

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev评测：题没变，AI却改了答案

Same Scores, Different Decisions

提问顺序与重复调用，都会进入这项评测。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

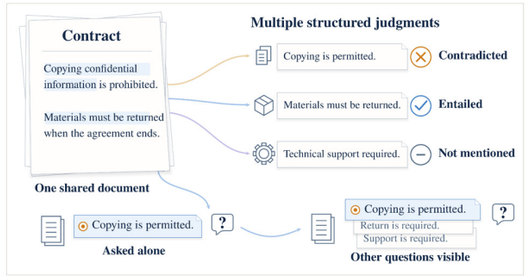

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

4次改对，4次改错，总分恰好没变

Qwen-3.5-4B在A/B两种安排的90组配对回答中，有9组答案不同：4组由错变对，4组由对变错，1组换成另一种错答案。

Model	Contrast	Valid pairs	Changed	Corrections	Regressions	Wrong-label changes	Net
Jev-1.13.0	A→B	90/90	4	4	0	0	+4
	B→C	90/90	1	0	1	0	−1
	C→D	90/90	0	0	0	0	0
Gemini-3.5-Flash	A→B	90/90	7	4	3	0	+1
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	6	1	5	0	−4
Gemini-3.1-Pro-Preview	A→B	89/90	7	3	4	0	−1
	B→C	90/90	7	4	3	0	+1
	C→D	90/90	3	0	3	0	−3
GPT-5.6-Luna	A→B	90/90	8	5	3	0	+2
	B→C	90/90	8	5	3	0	+2
	C→D	90/90	11	3	6	2	−3
GPT-5.6-Terra	A→B	90/90	7	6	0	1	+6
	B→C	90/90	7	3	3	1	0
	C→D	90/90	10	2	6	2	−4
GPT-6-Astra	A→B	90/90	4	1	3	0	−2
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	3	3	0	0	+3
Claude-Haiku-4.5	A→B	90/90	8	6	1	1	+5
	B→C	90/90	6	3	0	3	+3
	C→D	90/90	14	2	12	0	−10
Claude-Sonnet-5	A→B	90/90	5	3	2	0	+1
	B→C	90/90	6	5	1	0	+4
	C→D	90/90	3	1	0	2	+1
Qwen-3.5-4B	A→B	90/90	9	4	4	1	0
	B→C	88/90	9	7	1	1	+6
	C→D	87/90	14	5	8	1	−3
Qwen-3.5-9B	A→B	90/90	15	8	7	0	+1
	B→C	90/90	7	3	4	0	−1
	C→D	88/90	12	7	5	0	+2

相同的总分，可能对应不同的错题。

90组来自30道题各重复3次；9次变化涉及6道题。A/B分别为单独提问、展示17项但只回答目标题。

Table 10 · 首轮30题的配对回答 · 论文原图

AI 论文推荐 04 / 08

提问没变，答案也出现了变化

研究同时检查了两类变化：换一种提问安排后，答案是否改变；保持相同请求、重复调用时，答案是否改变。

	Across conditions			Identical-request repetition			
Model	A–B	B–C	C–D	A	B	C	D
Jev-1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini-3.5-Flash	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini-3.1-Pro-Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6-Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6-Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6-Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude-Haiku-4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude-Sonnet-5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen-3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen-3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

Qwen那6道变动的题，在相同请求下也变过。

因此，仅凭A/B之间的9次变化，还无法区分提问安排的影响与重复调用本身的波动。

Table 11 · 提问安排与重复调用 · 论文原图

01 Jev评测：题没变，AI却改了答案

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI却改了答案

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-8

Jev评测：题没变，AI却改了答案

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

用 Jev 审批合同，能省多少钱?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

用 Jev 审批合同，能省多少钱?

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

Aggregate accuracy summarizes how often a model is correct, but not which judgments remain correct when requests change. We evaluate Jev and nine language models on ContractNLI, with repeated requests that preserve the contract and target while varying visible hypotheses, requested answers, and output order. A four-model follow-up adds an equal-call repetition control and coverage of the remaining test contracts. Corrections and regressions can cancel, leaving unchanged accuracy despite changed decisions; consistent answers can also preserve errors. Majority voting over recorded responses yields small, uncertain gains, with repeated wrong answers accounting for much of the observed error. Gold-class diagnostics further reveal different error profiles behind aggregate model rankings. Resource comparisons add distinct trade-offs: Jev is cheapest and fastest for the joint baseline, while hosted language models achieve higher accuracy. Together, these findings connect decision-level evaluation to whether additional calls improve correctness and what the resulting decisions cost.

1 Introduction

模型调用费用

$0.000228

每份合同
一次请求17项判断

约为 Gemini Flash 的 1/6

基础准确率
Jev 77.38%
Flash 82.54%

模型调用费用尚不等于完整合同审批成本。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文推荐 03 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

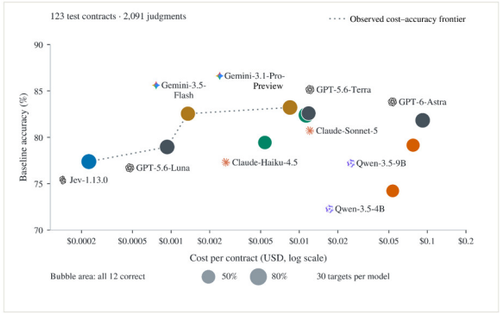

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 04 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

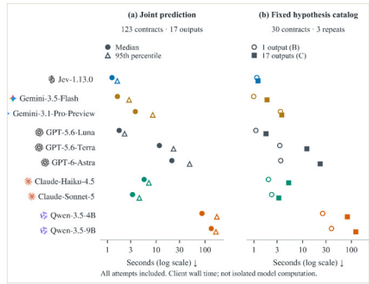

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

01 用 Jev 审批合同，能省多少钱?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

03 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

04 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

用 Jev 审批合同，能省多少钱?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题?

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

一次处理17项判断，Jev的模型调用费用约为Gemini-3.5-Flash的六分之一，准确率低5.16个百分点。这是论文测到的费用与效果差别。

合同审批还涉及人工复核和完整业务流程，论文没有统计这些费用，因此没有给出每份合同最终能节省多少钱。

论文报告的是模型调用费用，尚未测算完整审批成本。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题?

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-9

用 Jev 审批合同，能省多少钱?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

这篇论文给出了一笔模型调用费用：每份合同一次请求17项判断，Jev花费0.000228美元，Gemini-3.5-Flash为0.001353美元，前者约为后者的六分之一。

相应的基础准确率，Jev为77.38%，Gemini为82.54%。Jev调用费用较低，准确率也低5.16个百分点。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

已有回答的三次投票没有测出明确的准确率收益。模型调用更便宜，实际审批能否省下同样比例的钱，还取决于复核和业务流程；这些总成本不在论文的测量范围内。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI应用 #合同审核 #大模型评测 #推理成本 #论文分享

相同分数背后的判断变化与持续错误

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

01 相同分数背后的判断变化与持续错误

Same Scores, Different Decisions

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

相同分数背后的判断变化与持续错误

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

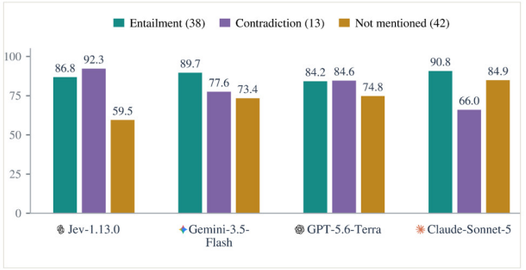

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

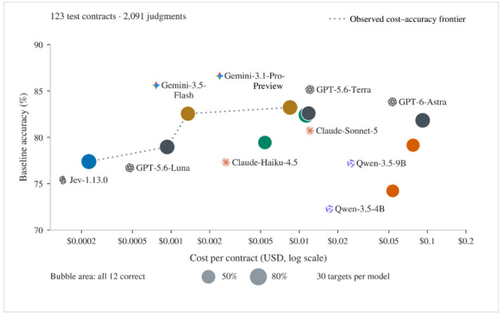

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-10

相同分数背后的判断变化与持续错误

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

论文推广 / A4-1-1

让AI去审批合同，结果如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

让AI去审批合同，结果如何?

Same Scores, Different Decisions

Evaluating Jev and Language Models
for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等
MBZUAI、东京大学等多机构合作

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

Aggregate accuracy summarizes how often a model is correct, but not which judgments remain correct when requests change. We evaluate Jev and nine language models on ContractNLI, with repeated requests that preserve the contract and target while varying visible hypotheses, requested answers, and output order. A four-model follow-up adds an equal-call repetition control and coverage of the remaining test contracts. Corrections and regressions can cancel, leaving unchanged accuracy despite changed decisions; consistent answers can also preserve errors. Majority voting over recorded responses yields small, uncertain gains, with repeated wrong answers accounting for much of the observed error. Gold-class diagnostics further reveal different error profiles behind aggregate model rankings. Resource comparisons add distinct trade-offs: Jev is cheapest and fastest for the joint baseline, while hosted language models achieve higher accuracy. Together, these findings connect decision-level evaluation to whether additional calls improve correctness and what the resulting decisions cost.

1 Introduction

Jev 合同评测

123份合同
2,091项判断

调用费用低
也有持续错题

每题重复
回答12次

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

01 让AI去审批合同，结果如何?

Same Scores, Different Decisions

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

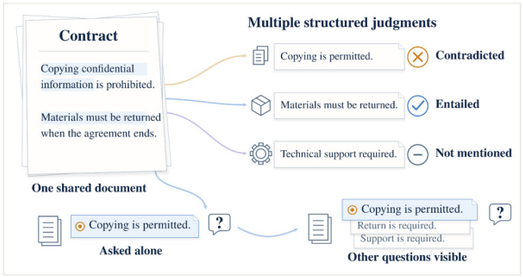

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

AI 论文推荐 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

AI 论文推荐 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI去审批合同，结果如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

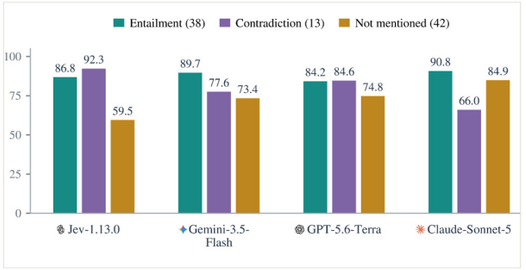

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-1

让AI去审批合同，结果如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

论文推广 / A4-1-2

相同分数背后的判断变化与持续错误

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

相同分数背后的判断变化与持续错误

Same Scores, Different Decisions

Evaluating Jev and Language Models for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等

MBZUAI、东京大学等多机构合作

Jev 合同评测

相同分数
不同判断

答案会变
错误会保留

重复提问
能纠错吗?

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

AI 论文推荐 02 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

01 相同分数背后的判断变化与持续错误

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

相同分数背后的判断变化与持续错误

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

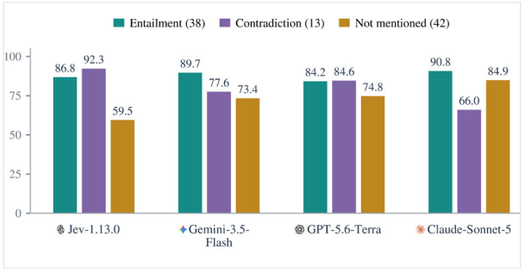

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

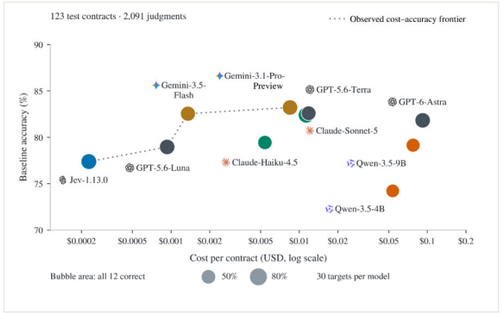

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-2

相同分数背后的判断变化与持续错误

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

Jev评测：题没变，AI却改了答案

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev评测：题没变，AI却改了答案

Same Scores, Different Decisions

Evaluating Jev and Language Models for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等

MBZUAI、东京大学等多机构合作

答案变化

同一份合同
同一道问题

9次答案变化
4次对→错

4次错→对
总分未变

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

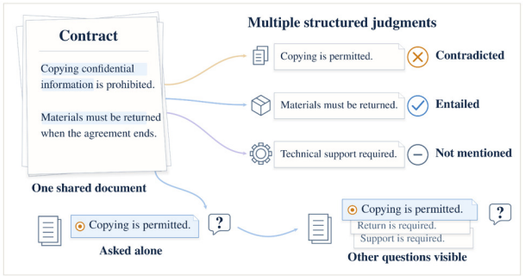

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

4次改对，4次改错，总分恰好没变

Qwen-3.5-4B在A/B两种安排的90组配对回答中，有9组答案不同：4组由错变对，4组由对变错，1组换成另一种错答案。

Model	Contrast	Valid pairs	Changed	Corrections	Regressions	Wrong-label changes	Net
Jev-1.13.0	A→B	90/90	4	4	0	0	+4
	B→C	90/90	1	0	1	0	−1
	C→D	90/90	0	0	0	0	0
Gemini-3.5-Flash	A→B	90/90	7	4	3	0	+1
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	6	1	5	0	−4
Gemini-3.1-Pro-Preview	A→B	89/90	7	3	4	0	−1
	B→C	90/90	7	4	3	0	+1
	C→D	90/90	3	0	3	0	−3
GPT-5.6-Luna	A→B	90/90	8	5	3	0	+2
	B→C	90/90	8	5	3	0	+2
	C→D	90/90	11	3	6	2	−3
GPT-5.6-Terra	A→B	90/90	7	6	0	1	+6
	B→C	90/90	7	3	3	1	0
	C→D	90/90	10	2	6	2	−4
GPT-6-Astra	A→B	90/90	4	1	3	0	−2
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	3	3	0	0	+3
Claude-Haiku-4.5	A→B	90/90	8	6	1	1	+5
	B→C	90/90	6	3	0	3	+3
	C→D	90/90	14	2	12	0	−10
Claude-Sonnet-5	A→B	90/90	5	3	2	0	+1
	B→C	90/90	6	5	1	0	+4
	C→D	90/90	3	1	0	2	+1
Qwen-3.5-4B	A→B	90/90	9	4	4	1	0
	B→C	88/90	9	7	1	1	+6
	C→D	87/90	14	5	8	1	−3
Qwen-3.5-9B	A→B	90/90	15	8	7	0	+1
	B→C	90/90	7	3	4	0	−1
	C→D	88/90	12	7	5	0	+2

相同的总分，可能对应不同的错题。

90组来自30道题各重复3次；9次变化涉及6道题。A/B分别为单独提问、展示17项但只回答目标题。

Table 10 · 首轮30题的配对回答 · 论文原图

AI 论文推荐 04 / 08

提问没变，答案也出现了变化

研究同时检查了两类变化：换一种提问安排后，答案是否改变；保持相同请求、重复调用时，答案是否改变。

	Across conditions			Identical-request repetition			
Model	A–B	B–C	C–D	A	B	C	D
Jev-1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini-3.5-Flash	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini-3.1-Pro-Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6-Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6-Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6-Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude-Haiku-4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude-Sonnet-5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen-3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen-3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

Qwen那6道变动的题，在相同请求下也变过。

因此，仅凭A/B之间的9次变化，还无法区分提问安排的影响与重复调用本身的波动。

Table 11 · 提问安排与重复调用 · 论文原图

01 Jev评测：题没变，AI却改了答案

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI却改了答案

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-3

Jev评测：题没变，AI却改了答案

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

Jev答题稳不稳？同一题测12次

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev答题稳不稳？同一题测12次

Same Scores, Different Decisions

Evaluating Jev and Language Models for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等

MBZUAI、东京大学等多机构合作

重复作答

93道题
每题12次

67道全对
17道持续错

一致回答中
也存在错误

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

AI 论文推荐 02 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 03 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 04 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

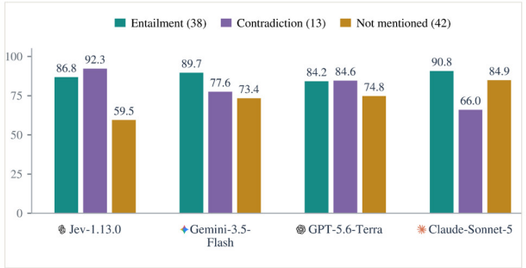

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

01 Jev答题稳不稳？同一题测12次

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

Jev答题稳不稳？同一题测12次

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响？

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题？

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响？

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题？

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-4

Jev答题稳不稳？同一题测12次

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

用 Jev 审批合同，能省多少钱?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

用 Jev 审批合同，能省多少钱?

Same Scores, Different Decisions

Evaluating Jev and Language Models for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等

MBZUAI、东京大学等多机构合作

模型调用费用

$0.000228

每份合同

约为Gemini Flash的1/6

一次请求

17项判断

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

AI 论文推荐 02 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文推荐 03 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

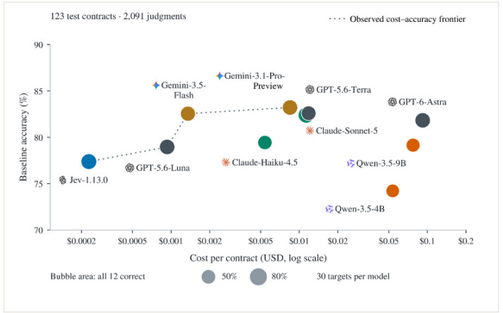

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 04 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

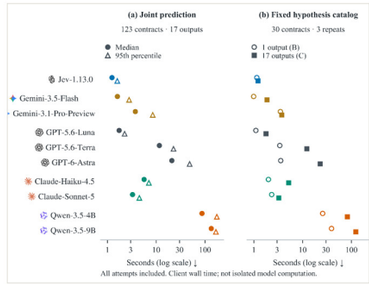

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

01 用 Jev 审批合同，能省多少钱?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

03 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

04 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

用 Jev 审批合同，能省多少钱?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题?

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

一次处理17项判断，Jev的模型调用费用约为Gemini-3.5-Flash的六分之一，准确率低5.16个百分点。这是论文测到的费用与效果差别。

合同审批还涉及人工复核和完整业务流程，论文没有统计这些费用，因此没有给出每份合同最终能节省多少钱。

论文报告的是模型调用费用，尚未测算完整审批成本。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题?

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-5

用 Jev 审批合同，能省多少钱?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

这篇论文给出了一笔模型调用费用：每份合同一次请求17项判断，Jev花费0.000228美元，Gemini-3.5-Flash为0.001353美元，前者约为后者的六分之一。

相应的基础准确率，Jev为77.38%，Gemini为82.54%。Jev调用费用较低，准确率也低5.16个百分点。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

已有回答的三次投票没有测出明确的准确率收益。模型调用更便宜，实际审批能否省下同样比例的钱，还取决于复核和业务流程；这些总成本不在论文的测量范围内。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI应用 #合同审核 #大模型评测 #推理成本 #论文分享

让AI处理合同，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

让AI处理合同，Jev表现如何?

123份合同，比较调用费用、准确率与持续错误。

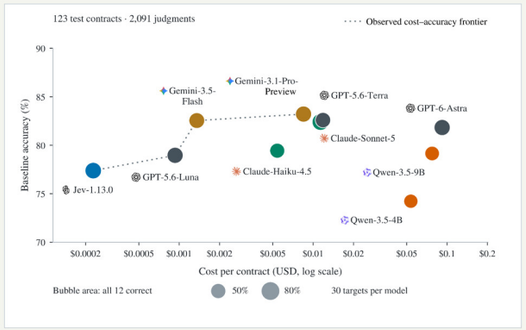

Jev 调用费用低、响应快，
同时也记录到一些持续错误。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

01 让AI处理合同，Jev表现如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

AI 论文解读 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

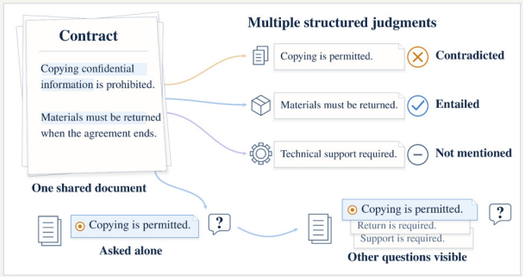

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

AI 论文解读 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	86.67	24/30	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

AI 论文解读 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

让AI处理合同，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

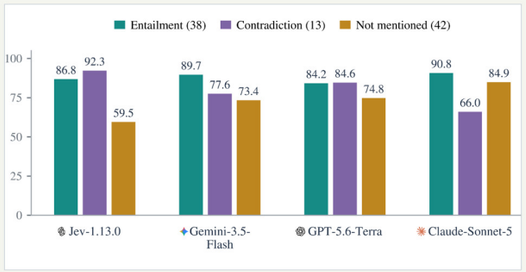

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 07 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 08 / 08

论文与代码

这项评测同时报告了调用费用、响应时间和答题表现。Jev在一次处理17项判断时费用最低、响应最快，但基础准确率低于部分语言模型。

重复测试还记录到持续错误。实验针对合同内容判断，尚未验证模型能否完成整套合同审批工作。

模型调用的效率优势，与答题错误同时存在。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A1-3

让AI处理合同，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

研究者把Jev和9个语言模型放进同一项合同测试，比较它们答得是否正确、调用费用多少，以及响应需要多久。材料来自123份合同，共2,091项判断。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文解读 #大模型评测 #AI可靠性 #自然语言处理

Jev便宜这么多，答题靠谱吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

Jev便宜这么多，答题靠谱吗?

123份合同 · 2,091项判断 · 重复作答测试

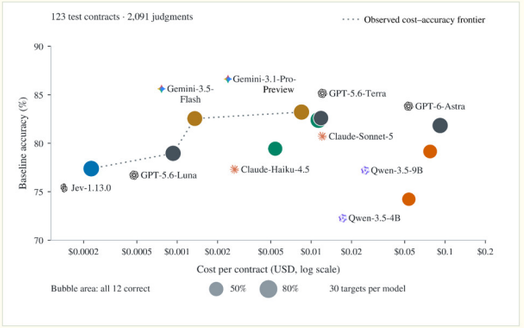

调用费用约为 Gemini-3.5-Flash 的 1/6。
基础准确率：77.38% 与 82.54%。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

AI 论文解读 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

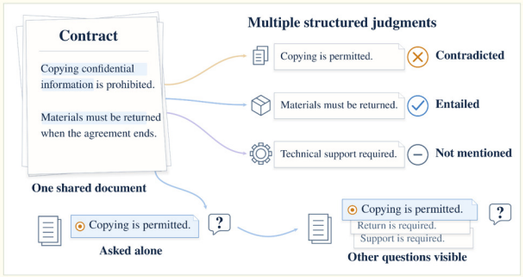

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文解读 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

01 Jev便宜这么多，答题靠谱吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

Jev便宜这么多，答题靠谱吗？

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文解读 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

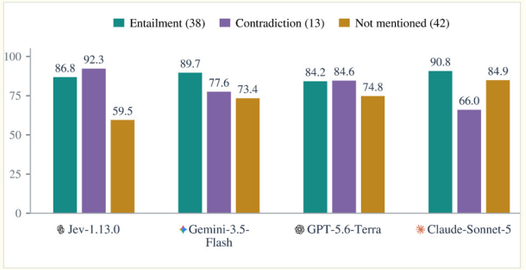

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 08 / 08

论文与代码

Jev在这项合同测试中的调用费用较低，不过原文未提及的内容仍较难判断。在93道题中，它有17道持续错题，13道属于“未提及”。

这些结果给出了低费用背后的具体表现。实际应用需要多少人工复核，以及总成本能省多少，论文没有测算。

“未提及”类问题，是这组实验中较集中的出错点。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A2-3

Jev便宜这么多，答题靠谱吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

一份合同同时回答17项判断，Jev的调用费用约为Gemini-3.5-Flash的六分之一。较低的价格之外，这篇论文也记录了它具体答错了什么。

基础准确率分别为77.38%和82.54%，Jev低5.16个百分点。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

在93道题中，Jev对“合同未提及”类问题的平均正确率为59.52%，“与合同矛盾”类为92.31%。两类分别有42道题和13道题。

对已有回答的三次投票，也没有测出明确的准确率提升。低费用带来了怎样的取舍，在具体错题中表现得更清楚。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #推理成本 #AI应用 #论文解读

AI做题，又快又准……吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

AI做题，又快又准……吗?

123份合同 · 2,091项判断 · 重复作答测试

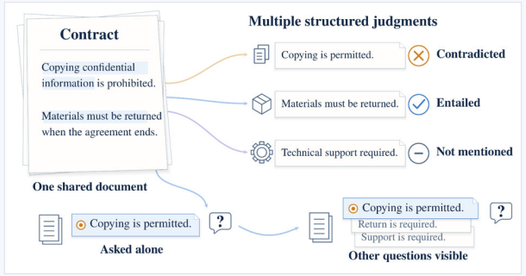

答得快、平均分高，
同一道题能不能一直答对?

Figure 1 完整示意图 · 论文原图

AI 论文解读 02 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文解读 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文解读 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

01 AI做题，又快又准……吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

AI做题，又快又准……吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 06 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

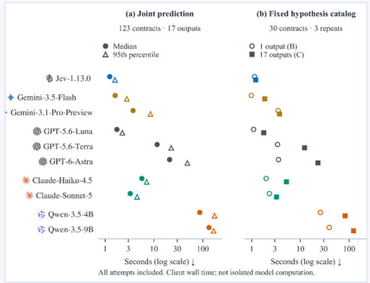

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

AI 论文解读 07 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 08 / 08

论文与代码

Jev一次回答17项判断时，响应时间最短，调用费用也最低。但在另外93道题的重复测试中，有17道题每次都给出同一个错答案。

研究者还从已有回答中取三次做投票，四个模型都没有测出明确的准确率提升。对于每次都给出相同错答案的题，投票也无法找回正确答案。

答得快的同时，也有一些题会反复答错。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

07 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A2-4

AI做题，又快又准……吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

一次回答17项合同判断，Jev在被测模型中响应最快、调用费用最低。但把同一道题反复问12次，部分错误也会一直保留。这篇评测把这些结果放在了一起。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

对已有回答的三次投票没有测出明确收益。研究展示了调用效率与答题错误同时存在的情况，评测范围是合同内容判断，并非完整审批流程。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型 #AI评测 #AI可靠性 #论文解读 #人工智能

Jev对比9个大模型，结果如何?

图片 01–04 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 10

Jev对比9个大模型，结果如何?

123份合同 · 2,091项判断 · 重复作答测试

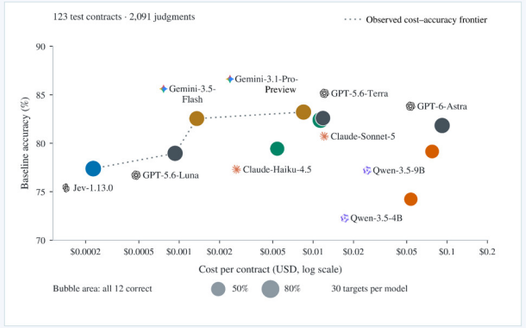

Jev 与 9 个语言模型的合同判断测试。
论文同时记录调用费用与持续错误。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

AI 论文解读 02 / 10

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

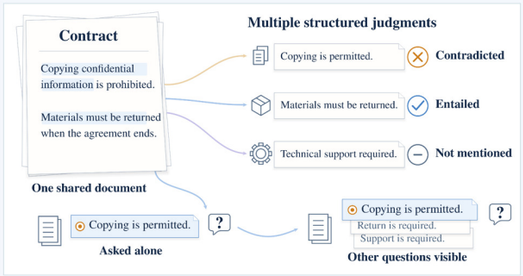

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文解读 03 / 10

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文解读 04 / 10

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

01 Jev对比9个大模型，结果如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

04 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

Jev对比9个大模型，结果如何?

图片 05–08 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 10

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文解读 06 / 10

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文解读 07 / 10

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

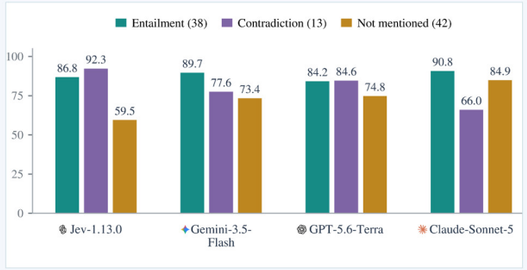

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 08 / 10

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

05 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

06 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

07 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

08 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

Jev对比9个大模型，结果如何?

图片 09–10 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

09 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

10 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A3-2

Jev对比9个大模型，结果如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

Jev对比9个语言模型，测试了123份合同、2,091项判断。除了准确率和调用费用，论文还记录了答案怎样变化，以及哪些错误会被反复保留。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文解读 #大模型评测 #AI可靠性 #自然语言处理 #LLM