让AI审批合同，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

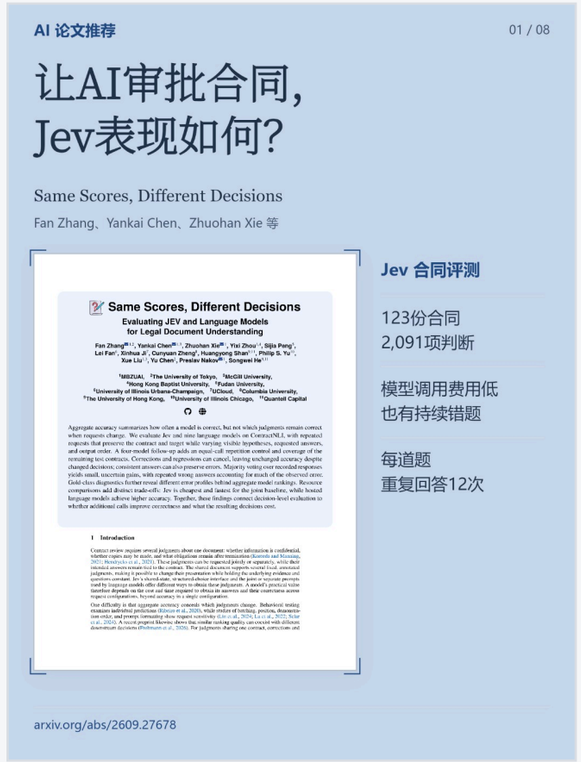

01 让AI审批合同，Jev表现如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI审批合同，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

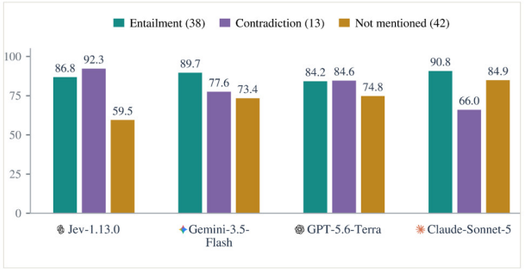

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1

让AI审批合同，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

论文推广 / A4-2

Jev的AI合同评测论文，讲了什么?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev的AI合同评测论文，讲了什么?

Same Scores, Different Decisions

Same Scores, Different Decisions

Evaluating JEV and Language Models for Legal Document Understanding

1 Introduction

研究比较 Jev 与 9 个语言模型

同一题反复作答，追踪答案变化与保留的错误。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

01 Jev的AI合同评测论文，讲了什么?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

Jev的AI合同评测论文，讲了什么?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

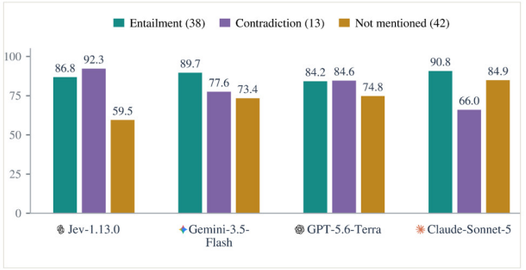

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

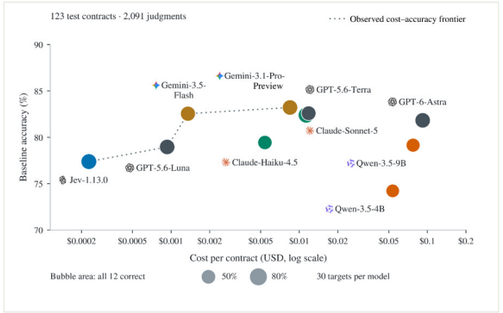

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-2

Jev的AI合同评测论文，讲了什么？

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

Jev评测：题没变，AI答案却变了

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

Same Scores, Different Decisions

Jev评测：题没变，AI答案却变了

相同总分下，可能答错了不同的题。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

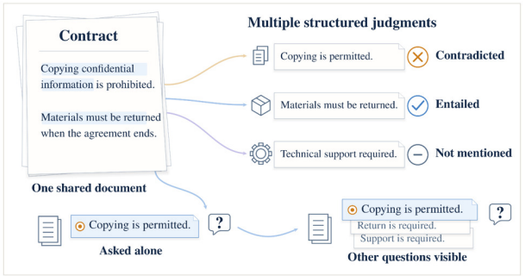

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

4次改对，4次改错，总分恰好没变

Qwen-3.5-4B在A/B两种安排的90组配对回答中，有9组答案不同：4组由错变对，4组由对变错，1组换成另一种错答案。

Model	Contrast	Valid pairs	Changed	Corrections	Regressions	Wrong-label changes	Net
Jev-1.13.0	A→B	90/90	4	4	0	0	+4
	B→C	90/90	1	0	1	0	−1
	C→D	90/90	0	0	0	0	0
Gemini-3.5-Flash	A→B	90/90	7	4	3	0	+1
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	6	1	5	0	−4
Gemini-3.1-Pro-Preview	A→B	89/90	7	3	4	0	−1
	B→C	90/90	7	4	3	0	+1
	C→D	90/90	3	0	3	0	−3
GPT-5.6-Luna	A→B	90/90	8	5	3	0	+2
	B→C	90/90	8	5	3	0	+2
	C→D	90/90	11	3	6	2	−3
GPT-5.6-Terra	A→B	90/90	7	6	0	1	+6
	B→C	90/90	7	3	3	1	0
	C→D	90/90	10	2	6	2	−4
GPT-6-Astra	A→B	90/90	4	1	3	0	−2
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	3	3	0	0	+3
Claude-Haiku-4.5	A→B	90/90	8	6	1	1	+5
	B→C	90/90	6	3	0	3	+3
	C→D	90/90	14	2	12	0	−10
Claude-Sonnet-5	A→B	90/90	5	3	2	0	+1
	B→C	90/90	6	5	1	0	+4
	C→D	90/90	3	1	0	2	+1
Qwen-3.5-4B	A→B	90/90	9	4	4	1	0
	B→C	88/90	9	7	1	1	+6
	C→D	87/90	14	5	8	1	−3
Qwen-3.5-9B	A→B	90/90	15	8	7	0	+1
	B→C	90/90	7	3	4	0	−1
	C→D	88/90	12	7	5	0	+2

相同的总分，可能对应不同的错题。

90组来自30道题各重复3次；9次变化涉及6道题。A/B分别为单独提问、展示17项但只回答目标题。

Table 10 · 首轮30题的配对回答 · 论文原图

AI 论文推荐 04 / 08

提问没变，答案也出现了变化

研究同时检查了两类变化：换一种提问安排后，答案是否改变；保持相同请求、重复调用时，答案是否改变。

	Across conditions			Identical-request repetition			
Model	A–B	B–C	C–D	A	B	C	D
Jev-1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini-3.5-Flash	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini-3.1-Pro-Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6-Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6-Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6-Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude-Haiku-4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude-Sonnet-5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen-3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen-3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

Qwen那6道变动的题，在相同请求下也变过。

因此，仅凭A/B之间的9次变化，还无法区分提问安排的影响与重复调用本身的波动。

Table 11 · 提问安排与重复调用 · 论文原图

01 Jev评测：题没变，AI答案却变了

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI答案却变了

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-3

Jev评测：题没变，AI答案却变了

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

让AI审批合同，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

让AI审批合同，Jev表现如何?

Same Scores, Different Decisions

Fan Zhang、Yankai Chen、Zhuohan Xie 等

123份合同

基础准确率
77.38%

Jev 调用费用
$0.000228
每份合同

合同内容判断 · 每次请求17项答案

arxiv.org/abs/2609.27678

01 让AI审批合同，Jev表现如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

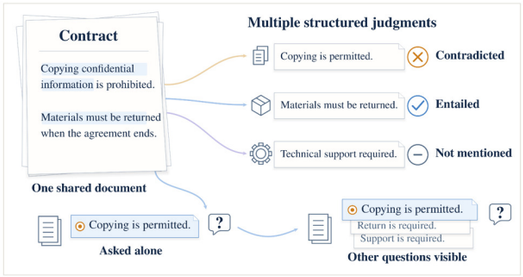

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

AI 论文推荐 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

AI 论文推荐 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI审批合同，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

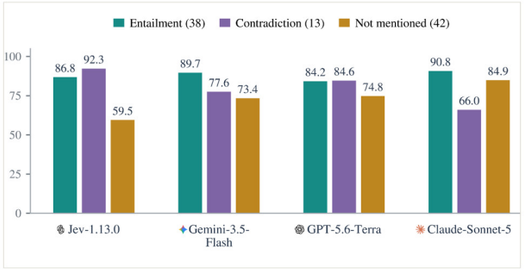

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-4

让AI审批合同，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

AI答题稳不稳？Jev同题测12次

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

AI答题稳不稳？Jev同题测12次

Same Scores, Different Decisions

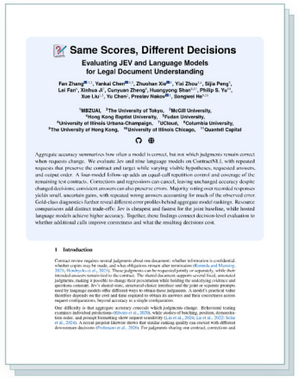

Table 4

模型	12次全对	始终同一错答
Jev-1.13.0	67/93	17
Gemini-3.5-Flash	66/93	11
GPT-5.6-Terra	64/93	8
Claude-Sonnet-5	70/93	6

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文推荐 03 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 04 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

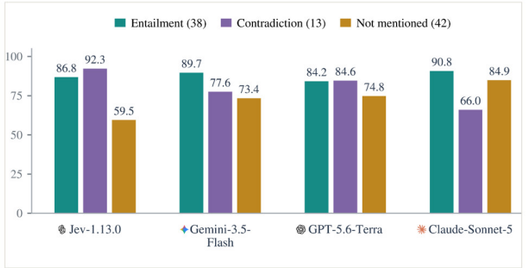

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

01 AI答题稳不稳？Jev同题测12次

论文首页 · Table 4 节选重排

高清原图 · 随本版下载包提供

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

AI答题稳不稳？Jev同题测12次

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响？

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题？

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响？

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题？

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-5

AI答题稳不稳？Jev同题测12次

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

Jev评测：AI分数一样，表现也一样吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

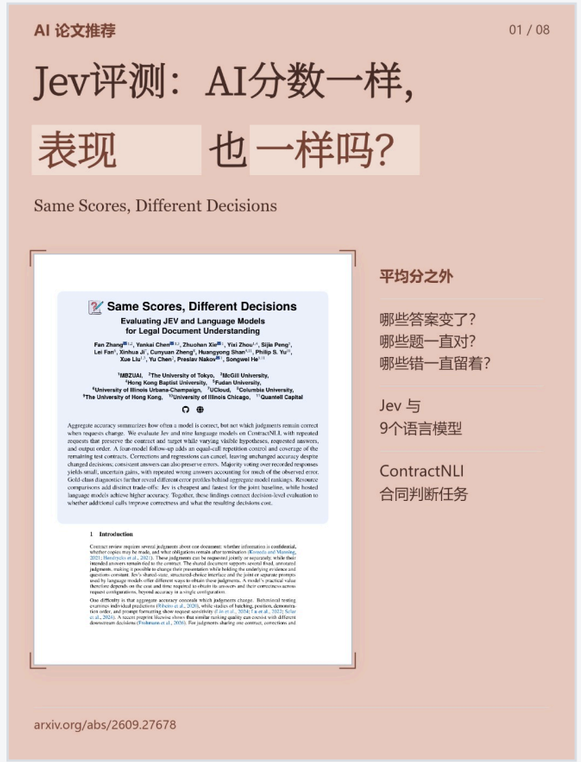

01 Jev评测：AI分数一样，表现也一样吗?

Same Scores, Different Decisions

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

高清原图 · 随本版下载包提供

Jev评测：AI分数一样，表现也一样吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

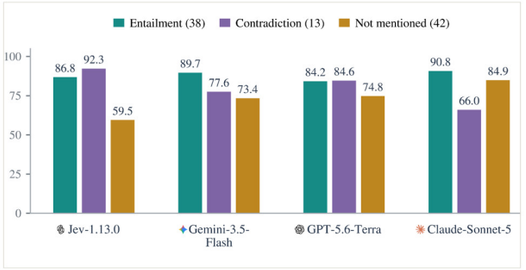

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

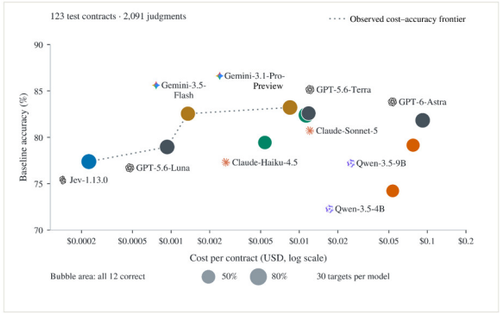

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-6

Jev评测：AI分数一样，表现也一样吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

让AI反复答同一道题，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

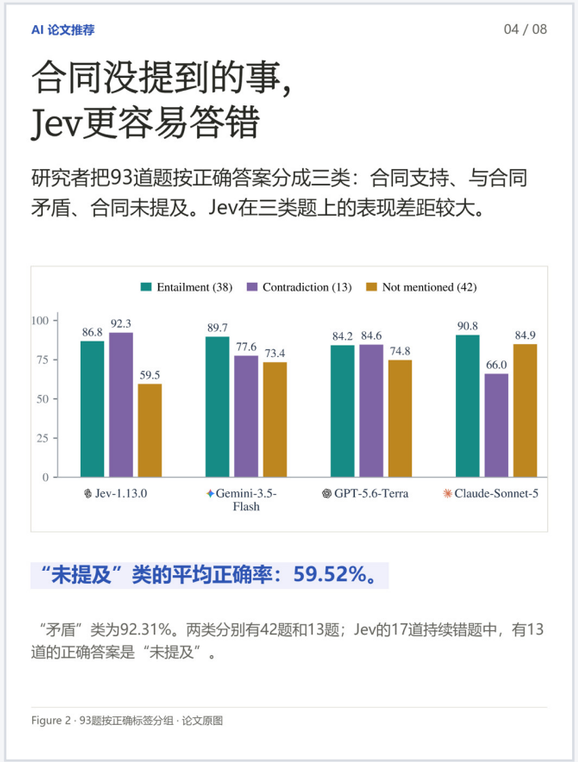

01 让AI反复答同一道题，Jev表现如何?

论文首页 · 据 Table 4 绘制

高清原图 · 随本版下载包提供

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

让AI反复答同一道题，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题?

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题?

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-7

让AI反复答同一道题，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

Jev评测：题没变，AI答案却变了

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

Jev评测：题没变，AI答案却变了

Same Scores, Different Decisions

提问顺序与重复调用，都会进入这项评测。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

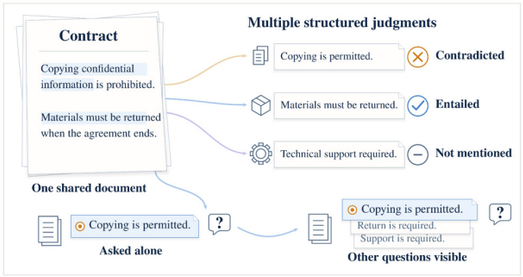

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文推荐 03 / 08

4次改对，4次改错，总分恰好没变

Qwen-3.5-4B在A/B两种安排的90组配对回答中，有9组答案不同：4组由错变对，4组由对变错，1组换成另一种错答案。

Model	Contrast	Valid pairs	Changed	Corrections	Regressions	Wrong-label changes	Net
Jev-1.13.0	A→B	90/90	4	4	0	0	+4
	B→C	90/90	1	0	1	0	−1
	C→D	90/90	0	0	0	0	0
Gemini-3.5-Flash	A→B	90/90	7	4	3	0	+1
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	6	1	5	0	−4
Gemini-3.1-Pro-Preview	A→B	89/90	7	3	4	0	−1
	B→C	90/90	7	4	3	0	+1
	C→D	90/90	3	0	3	0	−3
GPT-5.6-Luna	A→B	90/90	8	5	3	0	+2
	B→C	90/90	8	5	3	0	+2
	C→D	90/90	11	3	6	2	−3
GPT-5.6-Terra	A→B	90/90	7	6	0	1	+6
	B→C	90/90	7	3	3	1	0
	C→D	90/90	10	2	6	2	−4
GPT-6-Astra	A→B	90/90	4	1	3	0	−2
	B→C	90/90	3	2	1	0	+1
	C→D	90/90	3	3	0	0	+3
Claude-Haiku-4.5	A→B	90/90	8	6	1	1	+5
	B→C	90/90	6	3	0	3	+3
	C→D	90/90	14	2	12	0	−10
Claude-Sonnet-5	A→B	90/90	5	3	2	0	+1
	B→C	90/90	6	5	1	0	+4
	C→D	90/90	3	1	0	2	+1
Qwen-3.5-4B	A→B	90/90	9	5	4	1	0
	B→C	88/90	9	7	1	1	+6
	C→D	87/90	14	5	8	1	−3
Qwen-3.5-9B	A→B	90/90	15	8	7	0	+1
	B→C	90/90	7	3	4	0	−1
	C→D	88/90	12	7	5	0	+2

相同的总分，可能对应不同的错题。

90组来自30道题各重复3次；9次变化涉及6道题。A/B分别为单独提问、展示17项但只回答目标题。

Table 10 · 首轮30题的配对回答 · 论文原图

AI 论文推荐 04 / 08

提问没变，答案也出现了变化

研究同时检查了两类变化：换一种提问安排后，答案是否改变；保持相同请求、重复调用时，答案是否改变。

	Across conditions			Identical-request repetition			
Model	A–B	B–C	C–D	A	B	C	D
Jev-1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini-3.5-Flash	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini-3.1-Pro-Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6-Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6-Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6-Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude-Haiku-4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude-Sonnet-5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen-3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen-3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

Qwen那6道变动的题，在相同请求下也变过。

因此，仅凭A/B之间的9次变化，还无法区分提问安排的影响与重复调用本身的波动。

Table 11 · 提问安排与重复调用 · 论文原图

01 Jev评测：题没变，AI答案却变了

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI答案却变了

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-8

Jev评测：题没变，AI答案却变了

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

AI审核一份合同，Jev花多少钱?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

AI审核一份合同，Jev花多少钱?

Same Scores, Different Decisions
Evaluating JEV and Language Models for Legal Document Understanding

模型调用费用

$0.000228

每份合同
一次请求17项判断

约为 Gemini Flash 的 1/6

基础准确率
Jev 77.38%
Flash 82.54%

模型调用费用尚不等于完整合同审批成本。

arxiv.org/abs/2609.27678

AI 论文推荐 02 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文推荐 03 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

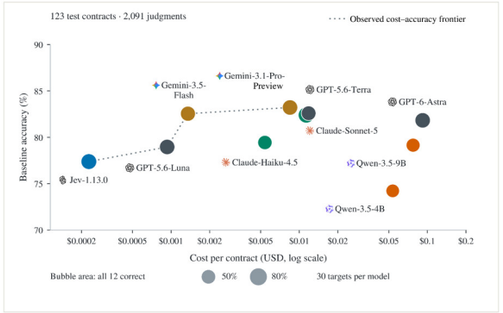

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 04 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

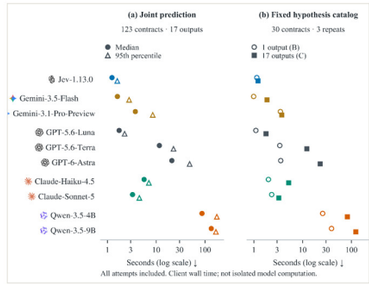

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

01 AI审核一份合同，Jev花多少钱?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

03 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

04 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

AI审核一份合同，Jev花多少钱?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题?

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

一次处理17项判断，Jev的模型调用费用约为Gemini-3.5-Flash的六分之一，准确率低5.16个百分点。这是论文测到的费用与效果差别。

合同审批还涉及人工复核和完整业务流程，论文没有统计这些费用，因此没有给出每份合同最终能节省多少钱。

论文报告的是模型调用费用，尚未测算完整审批成本。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题?

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-9

AI审核一份合同，Jev花多少钱?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

这篇论文给出了一笔模型调用费用：每份合同一次请求17项判断，Jev花费0.000228美元，Gemini-3.5-Flash为0.001353美元，前者约为后者的六分之一。

相应的基础准确率，Jev为77.38%，Gemini为82.54%。Jev调用费用较低，准确率也低5.16个百分点。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

已有回答的三次投票没有测出明确的准确率收益。模型调用更便宜，实际审批能否省下同样比例的钱，还取决于复核和业务流程；这些总成本不在论文的测量范围内。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI应用 #合同审核 #大模型评测 #推理成本 #论文分享

Jev评测：AI分数一样，表现也一样吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

01 Jev评测：AI分数一样，表现也一样吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

Jev评测：AI分数一样，表现也一样吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

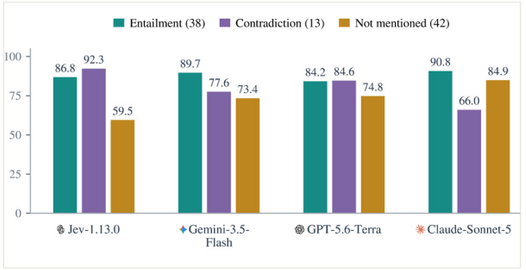

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

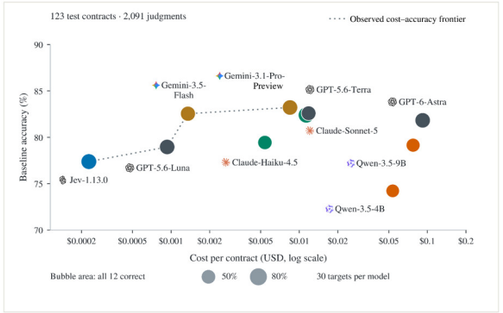

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-10

Jev评测：AI分数一样，表现也一样吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

论文推广 / A4-1-1

让AI审批合同，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

01 让AI审批合同，Jev表现如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

让AI审批合同，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

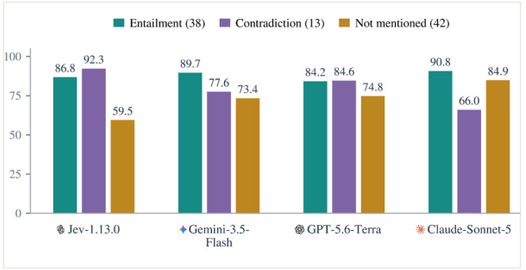

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这项研究评测的是合同审批中的一种基础能力：根据合同，判断一句话是否成立。Jev在模型调用费用上有优势，但也有一些题会反复答错。

实验没有覆盖完整审批流程或人工复核费用。它提供了合同内容判断的测试结果，供文档类AI应用参考。

Jev的低调用费用，与具体错题一并呈现。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-1

让AI审批合同，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

让AI审批合同，至少得先答对合同里的问题。这篇Jev评测从这一步入手：给定合同和一句陈述，判断原文支持、与原文矛盾，还是根本没有提到。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

对已有回答进行三次投票，也没有测出明确的准确率提升。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI评测 #合同审核 #大模型 #论文分享 #AI应用

论文推广 / A4-1-2

Jev评测：AI分数一样，表现也一样吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

01 Jev评测：AI分数一样，表现也一样吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

Jev评测：AI分数一样，表现也一样吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

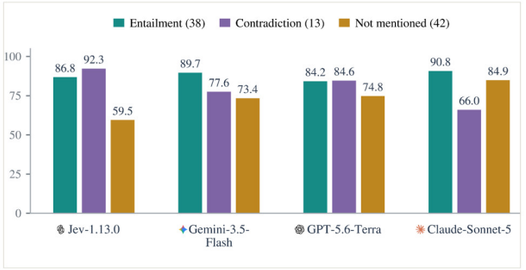

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文推荐 07 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

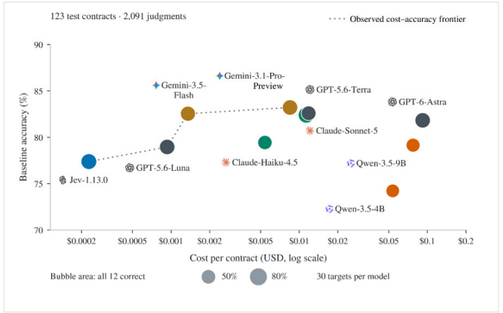

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 08 / 08

论文与代码

同样的平均分，可能来自不同的答题过程：有的题一直正确，有的题反复出错，也有的答案在多次调用间发生变化。

这篇论文记录了这些差别，并测试重复提问和多数投票能否修正错误。结果为合同类AI的评测补充了总分之外的信息。

研究关注判断怎样变化，以及哪些错误被保留下来。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-2

Jev评测：AI分数一样，表现也一样吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

两次测试总分一样，模型就表现一样吗？这篇Jev评测记录了一种情况：有些答案改对，有些改错，准确率恰好不变。它也关注另一类问题——无论问多少次，都重复同一个错误。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

反复调用后再投票，在这组测试中也没有显示明确收益。研究展示了总分之外的判断变化和持续错误。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文分享 #大模型评测 #AI可靠性 #LLM #人工智能

Jev评测：题没变，AI答案却变了

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

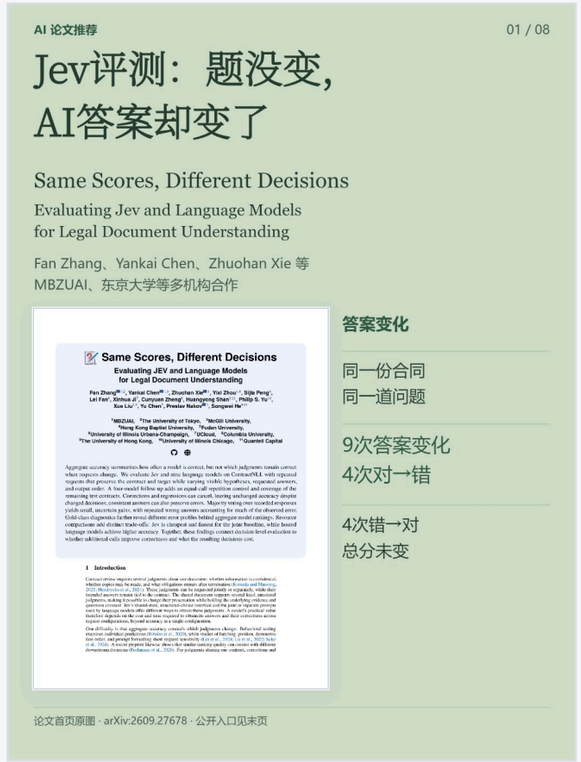

01 Jev评测：题没变，AI答案却变了

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 4次改对，4次改错，总分恰好没变

Table 10 · 首轮30题的配对回答

高清原图 · 随本版下载包提供

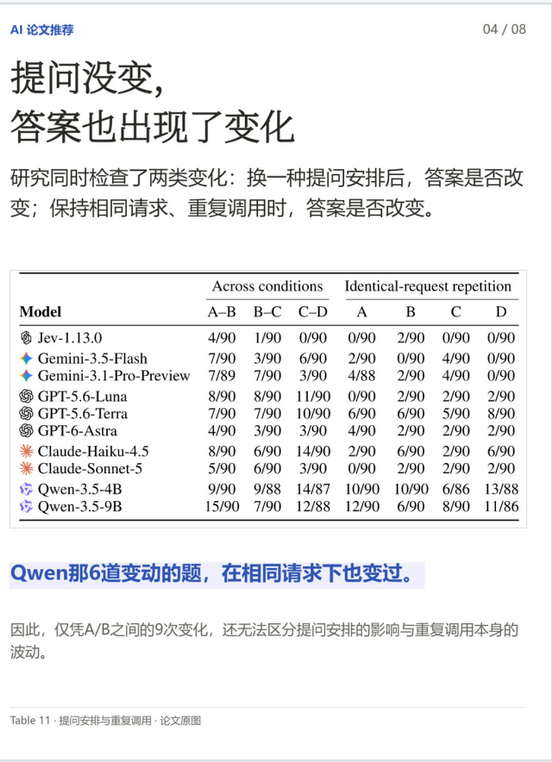

04 提问没变，答案也出现了变化

Table 11 · 提问安排与重复调用

高清原图 · 随本版下载包提供

Jev评测：题没变，AI答案却变了

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

AI 论文推荐 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 08 / 08

论文与代码

这篇论文展示了总分难以呈现的变化：部分答案改对，部分改错，最后的准确率可能恰好不变。保持同样请求、重复调用，也出现了答案波动。

研究分别记录这些现象，进一步检查哪些题始终正确、哪些错误始终保留。

相同总分下，模型可能答错了不同的题。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-3

Jev评测：题没变，AI答案却变了

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一份合同、同一道题，只是多展示几道问题，模型的答案就可能变化。Jev这篇评测把变化逐项记录下来：哪些由错变对，哪些由对变错，哪些换成了另一个错答案。

以Qwen-3.5-4B为例，A/B两种提问安排的90组配对回答中，有9组答案变化：4组改对、4组改错、1组换成另一个错答案，总分恰好抵消。这9次变化涉及6道题；相同请求下的重复调用也出现过答案波动。

等调用次数对照中，同样30道题一组重复相同请求12次，另一组使用四种安排各3次。Gemini平均正确率均为83.33%，12次全对的题数由25变为23；差异区间包含零，尚不能确定哪种安排更稳。

这项研究区分了跨提问安排的变化与相同请求下的波动，并进一步统计持续正确、持续错误和多数投票结果。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #提示词 #AI可靠性 #论文解读 #LLM

AI答题稳不稳？Jev同题测12次

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

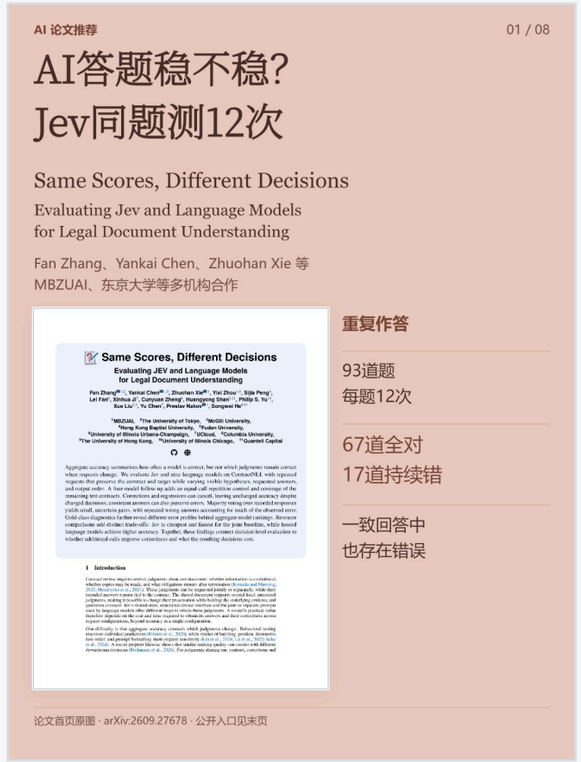

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	86.67	24/30	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

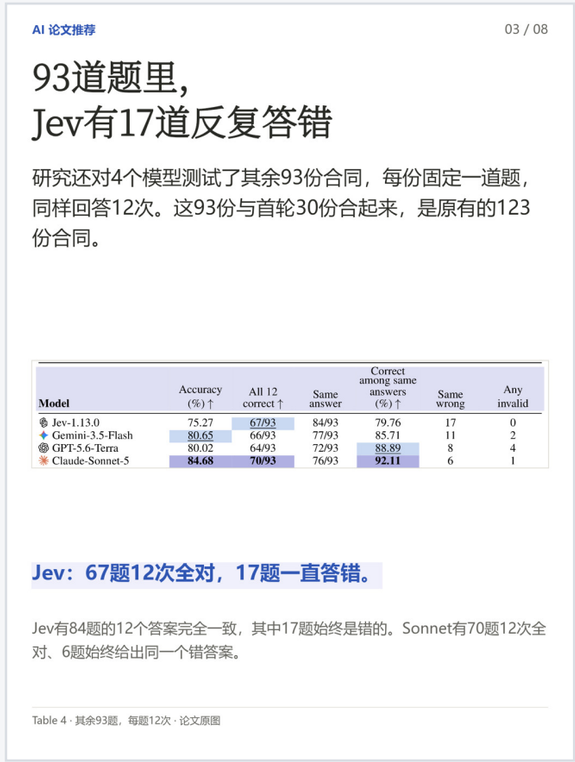

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

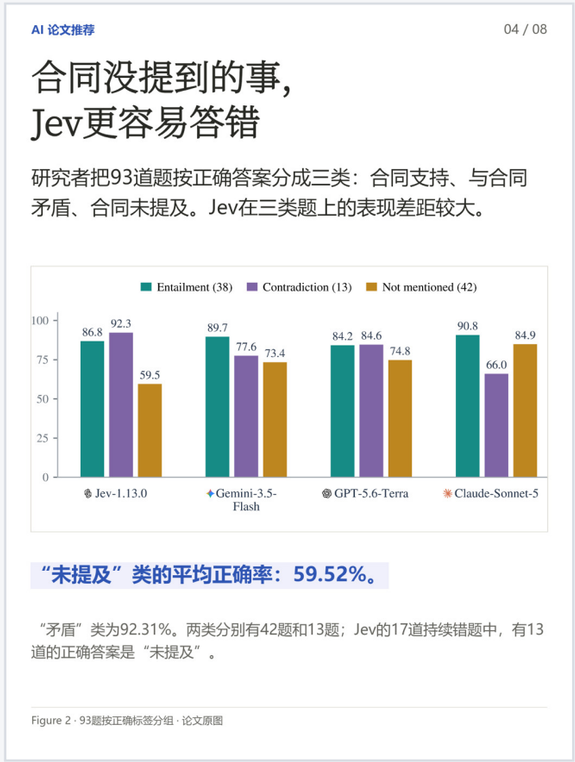

01 AI答题稳不稳？Jev同题测12次

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

03 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

04 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

AI答题稳不稳？Jev同题测12次

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

都问12次，换种问法有什么影响？

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题？

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

在93道题的测试里，Jev有84道始终给出相同答案，其中67道始终正确，17道始终错误。重复作答展示了两种不同的稳定表现。

基于已有回答的三次投票，也没有测出明确的准确率提升。实验结果仍限于这些合同、模型和请求配置。

17道题反复出现同一个错答案，投票也无法纠正。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 都问12次，换种问法有什么影响？

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题？

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-4

AI答题稳不稳？Jev同题测12次

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

同一道题问12次，结果会怎样？Jev这篇评测既记录一直答对的题，也记录每次都答错的题。两种表现都很“稳定”，实际意义却不同。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI可靠性 #大模型评测 #模型幻觉 #论文分享 #LLM

论文推广 / A4-1-5

AI审核合同，Jev能省多少调用费?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 01 / 08

AI审核合同，Jev能省多少调用费?

Same Scores, Different Decisions

Evaluating Jev and Language Models for Legal Document Understanding

Fan Zhang、Yankai Chen、Zhuohan Xie 等

MBZUAI、东京大学等多机构合作

Same Scores, Different Decisions

Evaluating JEV and Language Models for Legal Document Understanding

1 Introduction

模型调用费用

$0.000228

每份合同

约为Gemini Flash的1/6

一次请求 17项判断

论文首页原图 · arXiv:2609.27678 · 公开入口见末页

AI 论文推荐 02 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文推荐 03 / 08

调用费用相差数倍，准确率差多少?

横轴是每份合同的模型调用费用，纵轴是基础准确率。圆的大小表示首轮30题中，12次都答对的题目占比。

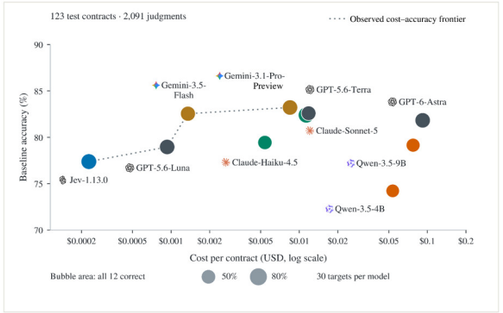

Jev费用更低；Flash的基础准确率更高。

坐标来自123份合同的基础测试，圆的大小来自首轮30题。虚线仅连接已测配置，中间位置没有对应的实测结果。

Figure 3 · 调用费用、准确率与持续正确 · 论文原图

AI 论文推荐 04 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

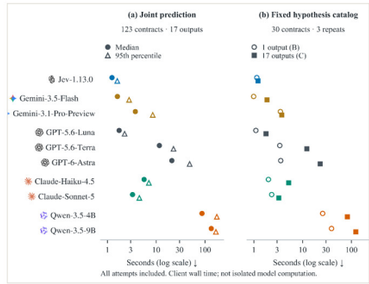

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

01 AI审核合同，Jev能省多少调用费?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

03 调用费用相差数倍，准确率差多少?

Figure 3 · 调用费用、准确率与持续正确

高清原图 · 随本版下载包提供

04 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

AI审核合同，Jev能省多少调用费?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文推荐 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文推荐 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文推荐 07 / 08

三次调用花三倍钱，投票能多答对几题?

在30题的等调用次数对照中，同一请求组内，三次调用的平均费用为单次的3倍。研究随后用这些回答计算多数投票的效果。

Model	Arm	Single	Vote-3	Pooled vote-5
Jev-1.13.0	Fixed	0.000134	0.000403	0.000671
	Varied	0.000196	0.000587	0.000979
Gemini-3.5-Flash	Fixed	0.000810	0.002430	0.004049
	Varied	0.001052	0.003155	0.005259
GPT-5.6-Terra	Fixed	0.002866	0.008599	0.014331
	Varied	0.006736	0.020207	0.033679
Claude-Sonnet-5	Fixed	0.010960	0.032881	0.054802
	Varied	0.011693	0.035080	0.058467

在这组测试中，增加调用未带来明确收益。

表中费用对应一道目标题的重复调用。基础测试每次请求17项判断，两类请求的输出量和计价单位不同。

Table 40 · 每道目标题的调用费用 · 论文原图

AI 论文推荐 08 / 08

论文与代码

一次处理17项判断，Jev的模型调用费用约为Gemini-3.5-Flash的六分之一，准确率低5.16个百分点。这是论文测到的费用与效果差别。

合同审批还涉及人工复核和完整业务流程，论文没有统计这些费用，因此没有给出每份合同最终能节省多少钱。

论文报告的是模型调用费用，尚未测算完整审批成本。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 三次调用花三倍钱，投票能多答对几题?

Table 40 · 每道目标题的调用费用

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文推广 / A4-1-5

AI审核合同，Jev能省多少调用费?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

这篇论文给出了一笔模型调用费用：每份合同一次请求17项判断，Jev花费0.000228美元，Gemini-3.5-Flash为0.001353美元，前者约为后者的六分之一。

相应的基础准确率，Jev为77.38%，Gemini为82.54%。Jev调用费用较低，准确率也低5.16个百分点。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

已有回答的三次投票没有测出明确的准确率收益。模型调用更便宜，实际审批能否省下同样比例的钱，还取决于复核和业务流程；这些总成本不在论文的测量范围内。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #AI应用 #合同审核 #大模型评测 #推理成本 #论文分享

让AI处理合同，Jev表现如何?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

让AI处理合同，Jev表现如何?

123份合同，比较调用费用、准确率与持续错误。

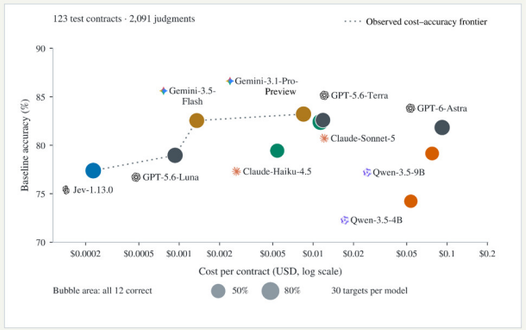

Jev 调用费用低、响应快，
同时也记录到一些持续错误。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

01 让AI处理合同，Jev表现如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

AI 论文解读 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

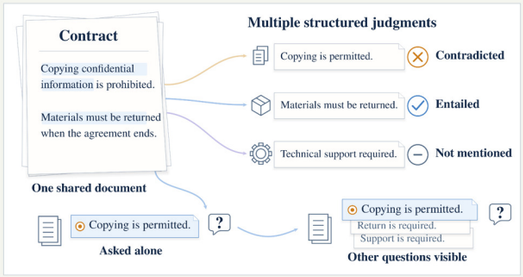

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

AI 论文解读 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	86.67	24/30	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

AI 论文解读 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

让AI处理合同，Jev表现如何?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

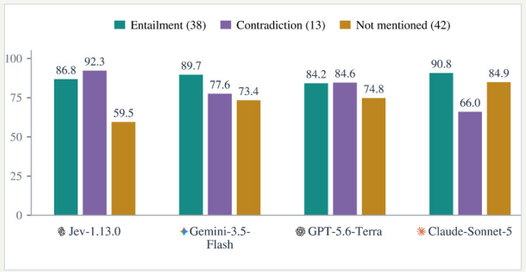

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 06 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 07 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 08 / 08

论文与代码

这项评测同时报告了调用费用、响应时间和答题表现。Jev在一次处理17项判断时费用最低、响应最快，但基础准确率低于部分语言模型。

重复测试还记录到持续错误。实验针对合同内容判断，尚未验证模型能否完成整套合同审批工作。

模型调用的效率优势，与答题错误同时存在。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

06 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

07 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A1-3

让AI处理合同，Jev表现如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

研究者把Jev和9个语言模型放进同一项合同测试，比较它们答得是否正确、调用费用多少，以及响应需要多久。材料来自123份合同，共2,091项判断。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文解读 #大模型评测 #AI可靠性 #自然语言处理

Jev成本很低，但AI真的靠谱吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

Jev成本很低，但AI真的靠谱吗?

123份合同 · 2,091项判断 · 重复作答测试

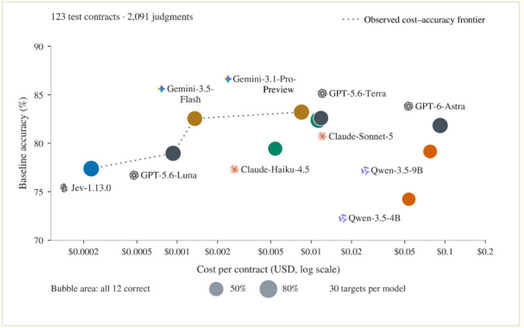

调用费用约为 Gemini-3.5-Flash 的 1/6。
基础准确率：77.38% 与 82.54%。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

AI 论文解读 02 / 08

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

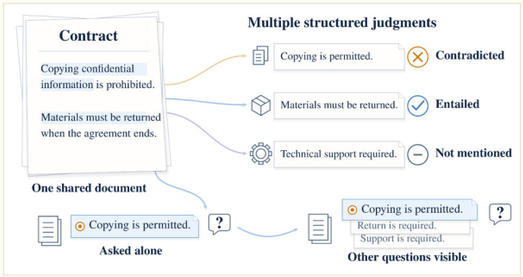

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文解读 03 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 04 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

01 Jev成本很低，但AI真的靠谱吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

04 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

Jev成本很低，但AI真的靠谱吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文解读 06 / 08

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

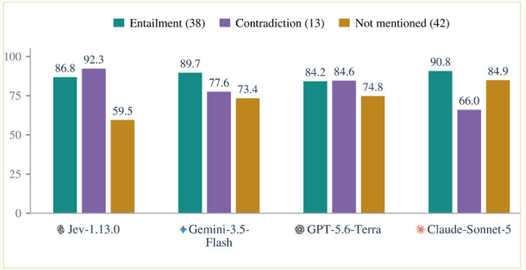

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 07 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 08 / 08

论文与代码

Jev在这项合同测试中的调用费用较低，不过原文未提及的内容仍较难判断。在93道题中，它有17道持续错题，13道属于“未提及”。

这些结果给出了低费用背后的具体表现。实际应用需要多少人工复核，以及总成本能省多少，论文没有测算。

“未提及”类问题，是这组实验中较集中的出错点。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

06 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

07 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A2-3

Jev成本很低，但AI真的靠谱吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

一份合同同时回答17项判断，Jev的调用费用约为Gemini-3.5-Flash的六分之一。较低的价格之外，这篇论文也记录了它具体答错了什么。

基础准确率分别为77.38%和82.54%，Jev低5.16个百分点。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

在93道题中，Jev对“合同未提及”类问题的平均正确率为59.52%，“与合同矛盾”类为92.31%。两类分别有42道题和13道题。

对已有回答的三次投票，也没有测出明确的准确率提升。低费用带来了怎样的取舍，在具体错题中表现得更清楚。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型评测 #推理成本 #AI应用 #论文解读

AI做题，Jev又快又准……吗?

图片 01–04 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 08

AI做题，Jev 又快又准……吗?

123份合同 · 2,091项判断 · 重复作答测试

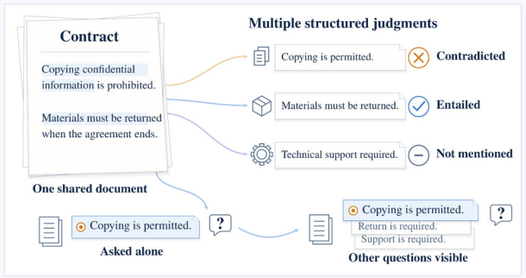

答得快、平均分高，
同一道题能不能一直答对?

Figure 1 完整示意图 · 论文原图

AI 论文解读 02 / 08

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文解读 03 / 08

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	**86.67**	**24/30**	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文解读 04 / 08

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	**84.68**	**70/93**	76/93	**92.11**	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

01 AI做题，Jev又快又准……吗?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

03 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

04 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

AI做题，Jev又快又准……吗?

图片 05–08 / 08 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 08

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

AI 论文解读 06 / 08

一次答17题，Jev的响应时间最短

基础测试每次要求17个判断，Jev的响应中位数为1.24秒，Gemini为1.60秒。只要求一个答案时，两者的快慢次序发生了变化。

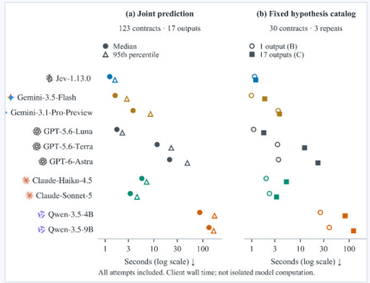

只答一题：Gemini 0.99秒，Jev 1.15秒。

单题条件仍展示17项问题，但只要求回答目标题。时间包含客户端、网络与服务开销，并非模型的纯计算时间。

Figure 6 · 请求输出数量与响应时间 · 论文原图

AI 论文解读 07 / 08

Jev 调用费用最低，准确率为77.38%

研究比较了Jev和9个语言模型，测试材料是123份合同、2,091项判断。每份合同一次请求17个答案。

Model	Baseline accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev-1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini-3.5-Flash	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini-3.1-Pro-Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6-Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6-Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6-Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude-Haiku-4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude-Sonnet-5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen-3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen-3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

每份合同调用费用：Jev $0.000228。

Gemini-3.5-Flash为$0.001353，约为Jev的6倍；准确率为82.54%，高5.16个百分点。价格对应评测时的配置。

Table 6 · 123份合同，每份17项判断 · 论文原图

AI 论文解读 08 / 08

论文与代码

Jev一次回答17项判断时，响应时间最短，调用费用也最低。但在另外93道题的重复测试中，有17道题每次都给出同一个错答案。

研究者还从已有回答中取三次做投票，四个模型都没有测出明确的准确率提升。对于每次都给出相同错答案的题，投票也无法找回正确答案。

答得快的同时，也有一些题会反复答错。

继续读论文

arxiv.org/abs/2609.27678

github.com/ZF-Utokyo/Jev-Benchmark

研究评测合同内容判断，未覆盖完整合同审批流程。

论文 §6、Limitations

05 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

06 一次答17题，Jev的响应时间最短

Figure 6 · 请求输出数量与响应时间

高清原图 · 随本版下载包提供

07 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

08 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A2-4

AI做题，Jev又快又准……吗?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

一次回答17项合同判断，Jev在被测模型中响应最快、调用费用最低。但把同一道题反复问12次，部分错误也会一直保留。这篇评测把这些结果放在了一起。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

响应速度也随请求内容变化：一次要求17项判断时，Jev为1.24秒，Gemini为1.60秒；同样展示17项问题、但只要求一个答案时，Gemini为0.99秒，Jev为1.15秒。以上均为客户端响应中位数。

对已有回答的三次投票没有测出明确收益。研究展示了调用效率与答题错误同时存在的情况，评测范围是合同内容判断，并非完整审批流程。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #大模型 #AI评测 #AI可靠性 #论文解读 #人工智能

Jev对比9个AI模型，结果如何?

图片 01–04 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 01 / 10

Jev对比9个AI模型，结果如何?

123份合同 · 2,091项判断 · 重复作答测试

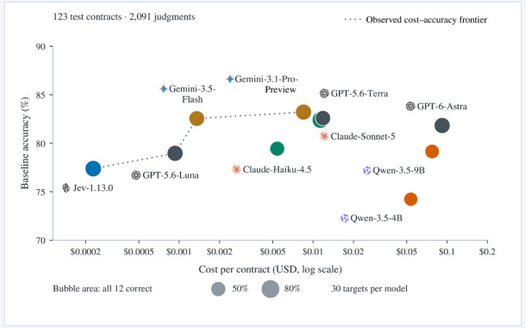

Jev 与 9 个语言模型的合同判断测试。
论文同时记录调用费用与持续错误。

Figure 3 完整坐标轴、气泡图及图例 · 论文原图

AI 论文解读 02 / 10

同一份合同，多放几道题会怎样?

研究者固定合同和一道目标题，只改变提问安排：单独问、同时展示其他问题，或调整回答顺序。合同没有变，正确答案也没有变。

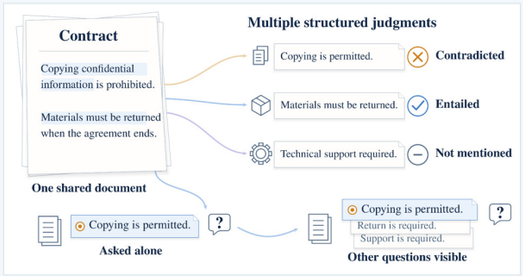

模型需要判断：合同是否支持这句话。

三个选项是“支持”“矛盾”和“未提及”。图中用保密条款举例，标签是参考答案，并非模型实测回答。

Figure 1 · 任务与提问方式示例 · 论文原图

AI 论文解读 03 / 10

都问12次，换种问法有什么影响?

同一批30道题分两组测试：一组重复相同请求12次，另一组用四种提问安排各问3次。两组在同一时期交错执行。

Model	Accuracy (%) ↑		All 12 correct ↑		Same answer	
	Fixed	Varied	Fixed	Varied	Fixed	Varied
Jev-1.13.0	80.56	79.17	24/30	**23/30**	29/30	29/30
Gemini-3.5-Flash	**83.33**	83.33	**25/30**	**23/30**	30/30	27/30
GPT-5.6-Terra	81.67	77.78	22/30	20/30	24/30	22/30
Claude-Sonnet-5	82.50	**85.28**	24/30	22/30	29/30	23/30

Gemini总分相同，12次全对的题数不同。

两组平均正确率均为83.33%，12次全对由25题变为23题。四模型差异区间均包含零，尚不能确定哪种安排更稳。

Table 3 · 30题，两组各调用12次 · 论文原图

AI 论文解读 04 / 10

改对的题和改错的题，可能被总分抵消

论文比较10个模型在三组提问条件下的答案变化，同时统计由错变对、由对变错，以及改成另一种错答案的次数。

Model	Visible questions A–B		Requested answers B–C		Requested order C–D	
	Changed answers	Δ correct	Changed answers	Δ correct	Changed answers	Δ correct
Jev-1.13.0	4/90	+4	1/90	-1	0/90	0
Gemini-3.5-Flash	7/90	+1	3/90	+1	6/90	-4
Gemini-3.1-Pro-Preview	7/89	-1	7/90	+1	3/90	-3
GPT-5.6-Luna	8/90	+2	8/90	+2	11/90	-3
GPT-5.6-Terra	7/90	+6	**7/90**	**0**	10/90	-4
GPT-6-Astra	4/90	-2	3/90	+1	3/90	+3
Claude-Haiku-4.5	8/90	+5	6/90	+3	14/90	-10
Claude-Sonnet-5	5/90	+1	6/90	+4	3/90	+1
Qwen-3.5-4B	**9/90**	**0**	9/88	+6	14/87	-3
Qwen-3.5-9B	15/90	+1	7/90	-1	12/88	+2

30组对照中，22组既有改对，也有改错。

总分记录最后答对多少，配对结果则能找到具体变了哪些答案。两种统计展示了不同的信息。

Table 1 · 10个模型，三组条件对照 · 论文原图

01 Jev对比9个AI模型，结果如何?

Same Scores, Different Decisions

高清原图 · 随本版下载包提供

02 同一份合同，多放几道题会怎样?

Figure 1 · 任务与提问方式示例

高清原图 · 随本版下载包提供

03 都问12次，换种问法有什么影响?

Table 3 · 30题，两组各调用12次

高清原图 · 随本版下载包提供

04 改对的题和改错的题，可能被总分抵消

Table 1 · 10个模型，三组条件对照

高清原图 · 随本版下载包提供

Jev对比9个AI模型，结果如何?

图片 05–08 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

AI 论文解读 05 / 10

平均分都约79%，12次全对的题数不同

研究者从30份合同中各选一道题，用四种提问安排各问3次。同一道题共回答12次，记录每次是否答对。

Model	Mean target accuracy (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev-1.13.0	79.44	23/30	5	2	0
Gemini-3.5-Flash	82.50	21/30	4	5	0
Gemini-3.1-Pro-Preview	85.28	22/30	2	5	1
GPT-5.6-Luna	81.94	22/30	3	5	0
GPT-5.6-Terra	80.56	20/30	2	8	0
GPT-6-Astra	76.39	22/30	6	2	0
Claude-Haiku-4.5	81.94	19/30	2	9	0
Claude-Sonnet-5	86.67	24/30	1	5	0
Qwen-3.5-4B	77.50	17/30	2	8	3
Qwen-3.5-9B	79.17	18/30	2	8	2

12次全对：Jev 23题，Qwen 18题。

两者平均正确率分别为79.44%和79.17%。Jev另有5题，12次都给出同一个错答案。这组结果来自30道题。

Table 2 · 首轮30题，每题12次 · 论文原图

AI 论文解读 06 / 10

93道题里，Jev有17道反复答错

研究还对4个模型测试了其余93份合同，每份固定一道题，同样回答12次。这93份与首轮30份合起来，是原有的123份合同。

Model	Accuracy (%) ↑	All 12 correct ↑	Same answer	Correct among same answers (%) ↑	Same wrong	Any invalid
Jev-1.13.0	75.27	67/93	84/93	79.76	17	0
Gemini-3.5-Flash	80.65	66/93	77/93	85.71	11	2
GPT-5.6-Terra	80.02	64/93	72/93	88.89	8	4
Claude-Sonnet-5	84.68	70/93	76/93	92.11	6	1

Jev：67题12次全对，17题一直答错。

Jev有84题的12个答案完全一致，其中17题始终是错的。Sonnet有70题12次全对、6题始终给出同一个错答案。

Table 4 · 其余93题，每题12次 · 论文原图

AI 论文解读 07 / 10

合同没提到的事，Jev更容易答错

研究者把93道题按正确答案分成三类：合同支持、与合同矛盾、合同未提及。Jev在三类题上的表现差距较大。

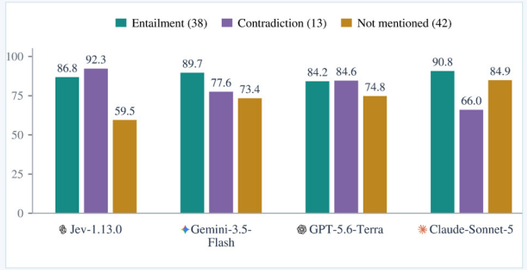

“未提及”类的平均正确率：59.52%。

“矛盾”类为92.31%。两类分别有42题和13题；Jev的17道持续错题中，有13道的正确答案是“未提及”。

Figure 2 · 93题按正确标签分组 · 论文原图

AI 论文解读 08 / 10

问三次再投票，没有明显提高准确率

研究者从已有记录中取三个回答，按多数票确定答案，并计算所有符合规则的组合。三种答案各一票时，记为答错。

Model	Fixed, 30 targets		Varied, 30 targets		Additional 93	
	Single	Vote-3	Single	Vote-3	Single	Vote-3
Jev-1.13.0	80.56	80.15	79.17	80.00	75.27	74.25
Gemini-3.5-Flash	83.33	83.33	83.33	84.44	80.65	81.00
GPT-5.6-Terra	81.67	81.76	77.78	77.96	80.02	79.37
Claude-Sonnet-5	82.50	82.91	85.28	85.86	84.68	84.05

四个模型均未测出明确的准确率提升。

93题中，Jev单次平均正确率75.27%，三次投票74.25%。差异区间包含零，尚不能确定投票让结果变好或变差。

Table 5 · 已记录回答的三次投票分析 · 论文原图

05 平均分都约79%，12次全对的题数不同

Table 2 · 首轮30题，每题12次

高清原图 · 随本版下载包提供

06 93道题里，Jev有17道反复答错

Table 4 · 其余93题，每题12次

高清原图 · 随本版下载包提供

07 合同没提到的事，Jev更容易答错

Figure 2 · 93题按正确标签分组

高清原图 · 随本版下载包提供

08 问三次再投票，没有明显提高准确率

Table 5 · 已记录回答的三次投票分析

高清原图 · 随本版下载包提供

Jev对比9个AI模型，结果如何?

图片 09–10 / 10 · 高清图片按相同编号收录于各版下载包

第三方简介 · 图文一起发布

09 Jev 调用费用最低，准确率为77.38%

Table 6 · 123份合同，每份17项判断

高清原图 · 随本版下载包提供

10 论文与代码

论文 §6、Limitations

高清原图 · 随本版下载包提供

论文解读 / A3-2

Jev对比9个AI模型，结果如何?

完整发布文案 · 文字可直接选择复制；本版下载包另附 TXT

第三方简介 · 图文一起发布

Jev对比9个语言模型，测试了123份合同、2,091项判断。除了准确率和调用费用，论文还记录了答案怎样变化，以及哪些错误会被反复保留。

基础测试中，Jev准确率为77.38%，每份合同调用费用0.000228美元；Gemini-3.5-Flash为82.54%、0.001353美元。Jev费用较低，准确率低5.16个百分点。

首轮30道题各回答12次。Jev与Qwen-3.5-9B的平均正确率分别为79.44%和79.17%，12次全对的题数却分别为23道和18道。Jev另有5道题，12次都给出同一个错答案。

研究还对4个模型测试其余93份合同，每份一道题、各问12次。Jev有67道题全对，17道题始终给出同一个错答案。其中13道持续错题的正确答案是“未提及”。

研究者用已记录的回答计算三次多数投票。四个模型都没有测出明确的准确率提升；Jev在93题中的单次均值为75.27%，投票后为74.25%，差异区间包含零。这个结果仅对应论文的样本和配置。

评测针对的是根据合同原文作判断，没有覆盖完整合同审批流程，也没有测算人工复核费用。论文与代码均有公开入口。

论文：https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#Jev #论文解读 #大模型评测 #AI可靠性 #自然语言处理 #LLM