让AI去审批合同，结果如何?

arXiv:2609.27678v1 [cs.CL] 23 Sep 2026

Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding

Fan Zhang[1,2] Yankai Chen[2,3] Zhuohan Xie[2] Yixi Zhou[4] Sijia Peng[5] Lei Fan[6] Xinhua Ji[7] Cunyuan Zheng[8] Huangyong Shan[9,11] Philip S. Yu[10] Xue Liu[2,3] Yu Chen[11] Preslav Nakov[2] Songwei He[9,11]

[1]The University of Tokyo [2]MBZUAI [3]McGill University [4]Hong Kong Baptist University [5]Fudan University [6]University of Illinois Urbana-Champaign [7]UCloud [8]Columbia University [9]The University of Hong Kong [10]University of Illinois Chicago [11]Quantell Capital

{fan.zhang, yankai.chen, zhuohan.xie, preslav.nakov}@mbzuai.ac.ae

Abstract

Contract inference requires multiple judgments about a shared document, but aggregate accuracy can conceal changes in the individual decisions. Repeated agreement is also insufficient: a model may consistently return the wrong answer. In this paper, we compare Jev with nine language models on ContractNLI, evaluating inference cost, response time, average correctness, and correctness across repeated request conditions. Controlled comparisons vary hypothesis visibility, requested outputs, and output order while keeping the contract and target judgment fixed. Jev has the lowest cost and median response time among the evaluated configurations, while hosted language models achieve higher baseline accuracy. Rankings by baseline accuracy differ from rankings by correctness across every condition and repeat, although small differences in the latter do not establish a general stability advantage. Development diagnostics further reveal compensating corrections and regressions, as well as persistent errors. These findings motivate evaluating cost and response time alongside whether individual judgments remain correct as the request configuration changes. Code: GitHub.

1 Introduction

Contract review requires several judgments about one document: whether information is confidential, whether copies may be made, and what obligations remain after termination (Koreeda and Manning, 2021; Hendrycks et al., 2021). These judgments can be requested jointly or separately, while their intended answers remain tied to the contract. A model's practical value therefore depends on the cost and time required to obtain its answers and their correctness across request configurations, beyond accuracy in a single configuration.

One difficulty is that aggregate accuracy conceals which judgments change. Behavioral testing examines individual predictions (Ribeiro et al., 2020), while studies of batching, position, demonstration order, and prompt formatting reveal request sensitivity (Lin et al., 2024; Lu et al., 2022; Sclar et al., 2024). A recent preprint likewise shows that similar ranking quality can coexist with different downstream decisions (Frohmann et al., 2026). For judgments sharing one contract, corrections and regressions can cancel each other out even when many decisions differ. Figure 1 (panel 2) illustrates this concern: Qwen3.5-4B changes its prediction for a fixed development-set judgment when more hypotheses become visible, although only the target label is requested.

A second difficulty is that agreement does not establish correctness: a model may repeat an incorrect label across every condition. Variation can also arise when an unchanged request is repeated. Evaluation must therefore score persistent answers against gold labels and use unchanged repetitions as a

01 · 原论文首页

AI 论文推荐 02 / 07

让AI去审批合同，结果如何?

审批合同，得先弄清条款到底怎么写。JEV这篇论文先测这一步：给AI合同原文，看它能不能答对相关问题。比如，合同要求复制保密资料前先取得书面同意，只在公司内部使用就可以直接复制吗?



原论文 Figure 1 · 任务定义

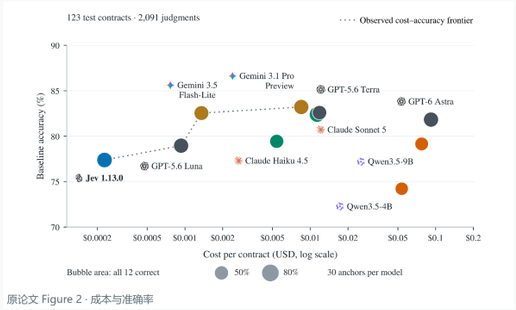
JEV · 根据原文回答问题 arXiv:2609.27678v1

02 · 让AI去审批合同，结果如何?

AI 论文推荐 03 / 07

答对多少之外，还要看什么?

这篇论文拿了123份合同、2091道问题，比较JEV和9个语言模型。除了看答对多少，也记录花多少钱、等多久，以及换一种提问安排，同一道题还能不能答对。



原论文 Figure 2 · 成本与准确率

JEV · 根据原文回答问题 arXiv:2609.27678v1

03 · 答对多少之外，还要看什么?

AI 论文推荐 04 / 07

同一道题，换四种安排来问

研究者从30份合同里各挑一道题，试了四种安排：单独问、连同其他题一起展示、要求一起作答，以及调整回答顺序。每种安排问3次，一道题共答12次。原文、问题和正确答案都不变。

Controlled request conditions. The stability study fixes one target hypothesis, called the anchor, for each selected test contract. Four conditions preserve its contract and gold label:

A. Only the anchor is visible; only its label is requested.
B. All 17 hypotheses are visible; only the anchor label is requested.
C. The same catalog is visible; all 17 labels are requested, anchor first.
D. The same catalog is visible; all 17 labels are requested, anchor last.

The catalog order is fixed in B/C/D. A–B changes visible hypotheses at a fixed requested answer set; B–C changes output workload and structure at fixed visible content; C–D changes requested output order and structure. Each condition is repeated three times. Primary scoring uses only the fixed anchor; the extra labels in C/D do not increase the number of primary targets.

原论文 §2 · 四种实验条件

JEV · 根据原文回答问题 arXiv:2609.27678v1

04 · 同一道题，换四种安排来问

让AI去审批合同，结果如何?

AI 论文推荐 05 / 07

平均分接近，一直答对的题却不同

这组重复测试里，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，JEV有23道，Qwen有18道。JEV也有5道题，12次都给了同一个错答案。

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	**86.67**	**24/30**	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 · 重复测试结果

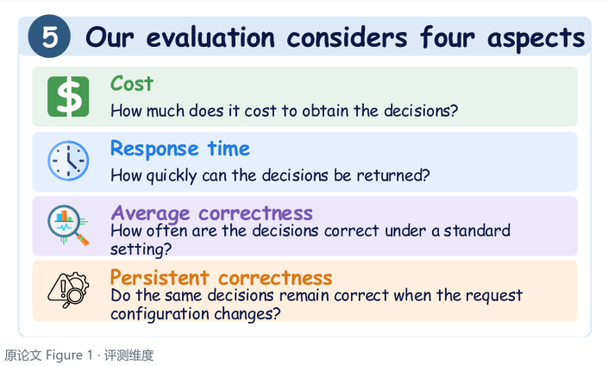
JEV · 根据原文回答问题 arXiv:2609.27678v1

05 · 平均分接近，一直答对的题却不同

AI 论文推荐 06 / 07

把一个总分，拆回具体的题

这篇论文值得看的地方，是把总分拆开，回到一道道题上：哪些一直对，哪些一直错，哪些会变。这样才更容易看清，两个分数接近的模型，到底差在哪。



原论文 Figure 1 · 评测维度

JEV · 根据原文回答问题 arXiv:2609.27678v1

06 · 把一个总分，拆回具体的题

AI 论文推荐 07 / 07

这些结果，能说明什么?

重复测试只有30道独立题，能说明的范围有限。这里考的是“能不能根据合同原文答对问题”，还没有检验AI能不能找全法律风险。如果你在研究AI阅读专业材料，可以从这篇入手。

继续阅读原论文

Same Scores, Different Decisions

JEV 与语言模型的阅读理解测试

arxiv.org/abs/2609.27678

JEV · 根据原文回答问题 arXiv:2609.27678v1

07 · 这些结果，能说明什么?

让AI去审批合同，结果如何?

审批合同，得先弄清条款到底怎么写。JEV这篇论文先测这一步：给AI合同原文，看它能不能答对相关问题。比如，合同要求复制保密资料前先取得书面同意，只在公司内部使用就可以直接复制吗?

这篇论文拿了123份合同、2091道问题，比较JEV和9个语言模型。除了看答对多少，也记录花多少钱、等多久，以及换一种提问安排，同一道题还能不能答对。

研究者从30份合同里各挑一道题，试了四种安排：单独问、连同其他题一起展示、要求一起作答，以及调整回答顺序。每种安排问3次，一道题共答12次。原文、问题和正确答案都不变。

这组重复测试里，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，JEV有23道，Qwen有18道。JEV也有5道题，12次都给了同一个错答案。

这篇论文值得看的地方，是把总分拆开，回到一道道题上：哪些一直对，哪些一直错，哪些会变。这样才更容易看清，两个分数接近的模型，到底差在哪。

重复测试只有30道独立题，能说明的范围有限。这里考的是“能不能根据合同原文答对问题”，还没有检验AI能不能找全法律风险。如果你在研究AI阅读专业材料，可以从这篇入手。

论文：Same Scores, Different Decisions（JEV与语言模型评测），arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678

#论文推荐 #JEV #大模型评测 #AI阅读理解

JEV的评测论文来了

arXiv:2609.27678v1 [cs.CL] 23 Sep 2026

Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding

Fan Zhang[1,2] Yankai Chen[2,3] Zhuohan Xie[2] Yixi Zhou[4] Sijia Peng[5] Lei Fan[6]
Xinhua Ji[7] Cunyuan Zheng[8] Huangyong Shan[9,11] Philip S. Yu[10] Xue Liu[2,3]
Yu Chen[11] Preslav Nakov[2] Songwei He[9,11]
[1]The University of Tokyo [2]MBZUAI [3]McGill University [4]Hong Kong Baptist University
[5]Fudan University [6]University of Illinois Urbana-Champaign [7]UCloud [8]Columbia University
[9]The University of Hong Kong [10]University of Illinois Chicago [11]Quantell Capital
{fan.zhang, yankai.chen, zhuohan.xie, preslav.nakov}@mbzuai.ac.ae

Abstract

Contract inference requires multiple judgments about a shared document, but aggregate accuracy can conceal changes in the individual decisions. Repeated agreement is also insufficient: a model may consistently return the wrong answer. In this paper, we compare Jev with nine language models on ContractNLI, evaluating inference cost, response time, average correctness, and correctness across repeated request conditions. Controlled comparisons vary hypothesis visibility, requested outputs, and output order while keeping the contract and target judgment fixed. Jev has the lowest cost and median response time among the evaluated configurations, while hosted language models achieve higher baseline accuracy. Rankings by baseline accuracy differ from rankings by correctness across every condition and repeat, although small differences in the latter do not establish a general stability advantage. Development diagnostics further reveal compensating corrections and regressions, as well as persistent errors. These findings motivate evaluating cost and response time alongside whether individual judgments remain correct as the request configuration changes. Code: GitHub.

1 Introduction

Contract review requires several judgments about one document: whether information is confidential, whether copies may be made, and what obligations remain after termination (Koreeda and Manning, 2021; Hendrycks et al., 2021). These judgments can be requested jointly or separately, while their intended answers remain tied to the contract. A model's practical value therefore depends on the cost and time required to obtain its answers and their correctness across request configurations, beyond accuracy in a single configuration.

One difficulty is that aggregate accuracy conceals which judgments change. Behavioral testing examines individual predictions (Ribeiro et al., 2020), while studies of batching, position, demonstration order, and prompt formatting reveal request sensitivity (Lin et al., 2024; Lu et al., 2022; Sclar et al., 2024). A recent preprint likewise shows that similar ranking quality can coexist with different downstream decisions (Frohmann et al., 2026). For judgments sharing one contract, corrections and regressions can cancel each other out even when many decisions differ. Figure 1 (panel 2) illustrates this concern: Qwen3.5-4B changes its prediction for a fixed development-set judgment when more hypotheses become visible, although only the target label is requested.

A second difficulty is that agreement does not establish correctness: a model may repeat an incorrect label across every condition. Variation can also arise when an unchanged request is repeated. Evaluation must therefore score persistent answers against gold labels and use unchanged repetitions as a

01 · 原论文首页

AI 论文推荐 02 / 07

JEV的评测论文来了

JEV的评测论文已在arXiv公开。这次研究比较了JEV和9个语言模型，其中一组结果很有意思：一个模型答对286次，另一个答对285次。总分几乎一样，每道题的表现却不一样。

阅读线索

Table 2 · 重复测试结果

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

02 · JEV的评测论文来了

AI 论文推荐 03 / 07

两个约79%，是怎么测出来的?

论文选了30道根据合同内容作答的问题，换四种提问安排，每种问3次，每个模型共答360次。JEV答对286次，Qwen3.5-9B答对285次，平均正确率分别为79.44%和79.17%。

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	**86.67**	**24/30**	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 · 同一组重复测试

JEV · 根据原文回答问题 arXiv:2609.27678v1

03 · 两个约79%，是怎么测出来的?

AI 论文推荐 04 / 07

一直答对的题，一个23道，一个18道

把结果按题目排在一起，差别就出来了：JEV有23道题，12次全部答对；Qwen3.5-9B有18道。答对的总数接近，不代表一直答对的是同样多的题。

阅读线索

Table 2 · Always-correct targets

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

04 · 一直答对的题，一个23道，一个18道

JEV的评测论文来了

AI 论文推荐 05 / 07

同样的平均分，错误分布并不一样

再看错题。JEV有5道题一直给同一个错答案，2道题的答案变过。Qwen3.5-9B有2道题一直答错，8道题给出过不同的有效答案，还有2道题至少出现过一次无效回答。

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	**86.67**	**24/30**	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 · 各类回答结果

JEV · 根据原文回答问题 arXiv:2609.27678v1

05 · 同样的平均分，错误分布并不一样

AI 论文推荐 06 / 07

分数相近，具体判断仍有差别

这也是论文标题“相同分数，不同判断”的意思。看榜单能知道模型一共答对多少；把每道题的回答展开看，才知道错误都发生在哪里。

阅读线索

论文标题 · Same Scores, Different Decisions

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

06 · 分数相近，具体判断仍有差别

AI 论文推荐 07 / 07

看完总分，再翻到Table 2

这次只有30道独立题，不能据此说哪个模型在所有任务上都更好。比较两个分数很接近的模型时，倒是可以借鉴这个看法：除了总分，也看看每道题的记录。具体结果在Table 2。

继续阅读原论文

Same Scores, Different Decisions

JEV 与语言模型的阅读理解测试

arxiv.org/abs/2609.27678

JEV · 根据原文回答问题 arXiv:2609.27678v1

07 · 看完总分，再翻到Table 2

JEV的评测论文来了

JEV的评测论文已在arXiv公开。这次研究比较了JEV和9个语言模型，其中一组结果很有意思：一个模型答对286次，另一个答对285次。总分几乎一样，每道题的表现却不一样。

论文选了30道根据合同内容作答的问题，换四种提问安排，每种问3次，每个模型共答360次。JEV答对286次，Qwen3.5-9B答对285次，平均正确率分别为79.44%和79.17%。

把结果按题目排在一起，差别就出来了：JEV有23道题，12次全部答对；Qwen3.5-9B有18道。答对的总数接近，不代表一直答对的是同样多的题。

再看错题。JEV有5道题一直给同一个错答案，2道题的答案变过。Qwen3.5-9B有2道题一直答错，8道题给出过不同的有效答案，还有2道题至少出现过一次无效回答。

这也是论文标题“相同分数，不同判断”的意思。看榜单能知道模型一共答对多少；把每道题的回答展开看，才知道错误都发生在哪里。

这次只有30道独立题，不能据此说哪个模型在所有任务上都更好。比较两个分数很接近的模型时，倒是可以借鉴这个看法：除了总分，也看看每道题的记录。具体结果在Table 2。

论文：Same Scores, Different Decisions（JEV与语言模型评测），arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678

#论文推荐 #JEV #AI评测 #大模型

JEV评测：题没变，AI却改了答案



arXiv:2609.27678v1 [cs.CL] 23 Sep 2026

Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding

Fan Zhang[1,2] Yankai Chen[2,3] Zhuohan Xie[2] Yixi Zhou[4] Sijia Peng[5] Lei Fan[6] Xinhua Ji[7] Cunyuan Zheng[8] Huangyong Shan[9,11] Philip S. Yu[10] Xue Liu[2,3] Yu Chen[11] Preslav Nakov[2] Songwei He[9,11]

[1]The University of Tokyo [2]MBZUAI [3]McGill University [4]Hong Kong Baptist University [5]Fudan University [6]University of Illinois Urbana-Champaign [7]UCloud [8]Columbia University [9]The University of Hong Kong [10]University of Illinois Chicago [11]Quantell Capital

{fan.zhang, yankai.chen, zhuohan.xie, preslav.nakov}@mbzuai.ac.ae

Abstract

Contract inference requires multiple judgments about a shared document, but aggregate accuracy can conceal changes in the individual decisions. Repeated agreement is also insufficient: a model may consistently return the wrong answer. In this paper, we compare Jev with nine language models on ContractNLI, evaluating inference cost, response time, average correctness, and correctness across repeated request conditions. Controlled comparisons vary hypothesis visibility, requested outputs, and output order while keeping the contract and target judgment fixed. Jev has the lowest cost and median response time among the evaluated configurations, while hosted language models achieve higher baseline accuracy. Rankings by baseline accuracy differ from rankings by correctness across every condition and repeat, although small differences in the latter do not establish a general stability advantage. Development diagnostics further reveal compensating corrections and regressions, as well as persistent errors. These findings motivate evaluating cost and response time alongside whether individual judgments remain correct as the request configuration changes. Code: GitHub.

1 Introduction

Contract review requires several judgments about one document: whether information is confidential, whether copies may be made, and what obligations remain after termination (Koreeda and Manning, 2021; Hendrycks et al., 2021). These judgments can be requested jointly or separately, while their intended answers remain tied to the contract. A model's practical value therefore depends on the cost and time required to obtain its answers and their correctness across request configurations, beyond accuracy in a single configuration.

One difficulty is that aggregate accuracy conceals which judgments change. Behavioral testing examines individual predictions (Ribeiro et al., 2020), while studies of batching, position, demonstration order, and prompt formatting reveal request sensitivity (Lin et al., 2024; Lu et al., 2022; Sclar et al., 2024). A recent preprint likewise shows that similar ranking quality can coexist with different downstream decisions (Frohmann et al., 2026). For judgments sharing one contract, corrections and regressions can cancel each other out even when many decisions differ. Figure 1 (panel 2) illustrates this concern: Qwen3.5-4B changes its prediction for a fixed development-set judgment when more hypotheses become visible, although only the target label is requested.

A second difficulty is that agreement does not establish correctness: a model may repeat an incorrect label across every condition. Variation can also arise when an unchanged request is repeated. Evaluation must therefore score persistent answers against gold labels and use unchanged repetitions as a

01 · 原论文首页

题没变，AI却改了答案

JEV这篇评测论文里，有一组专门比较提问安排的实验：同一份合同、同一道题，只在旁边多放16道不用回答的问题，AI会不会改答案？参与这组对照的是Qwen3.5-4B。



原论文 Figure 1 · 根据原文回答问题

02 · 题没变，AI却改了答案

多出来的16道题，只展示，不作答

A组只展示原题；B组把同一份合同的17道题都展示出来，但也只要求回答原题。两组的问题和正确答案相同，区别在于能不能看见另外16道题。

Controlled request conditions. The stability study fixes one target hypothesis, called the anchor, for each selected test contract. Four conditions preserve its contract and gold label:

A. Only the anchor is visible; only its label is requested.
B. All 17 hypotheses are visible; only the anchor label is requested.
C. The same catalog is visible; all 17 labels are requested, anchor first.
D. The same catalog is visible; all 17 labels are requested, anchor last.

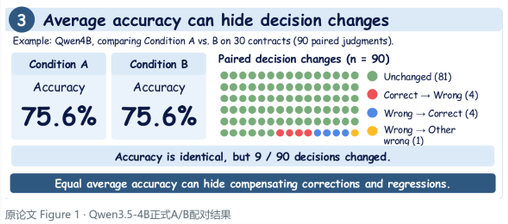
The catalog order is fixed in B/C/D. A–B changes visible hypotheses at a fixed requested answer set; B–C changes output workload and structure at fixed visible content; C–D changes requested output order and structure. Each condition is repeated three times. Primary scoring uses only the fixed anchor; the extra labels in C/D do not increase the number of primary targets.

原论文 §2 · 条件A与条件B

03 · 多出来的16道题，只展示，不作答

90组配对里，有9组答案变了

30道题，每种安排问3次，得到90组配对。Qwen3.5-4B有9组答案变了：4组改对，4组改错，还有1组从一种错答案换成另一种。



原论文 Figure 1 · Qwen3.5-4B正式A/B配对结果

04 · 90组配对里，有9组答案变了

JEV评测：题没变，AI却改了答案

AI 论文推荐 05 / 07

总分没变，具体的答案变了

改对4组，又改错4组，答对的总数刚好没变。只看准确率，两组似乎一样；回到具体某一道题，拿到的答案却可能不同。

阅读线索

§4.3 · 配对后的答案变化

完整文案与论文链接见发布正文

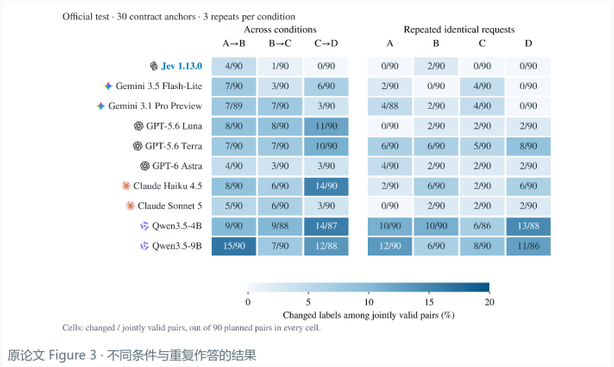
JEV · 根据原文回答问题 arXiv:2609.27678v1

05 · 总分没变，具体的答案变了

AI 论文推荐 06 / 07

这9组变化，不能全算在额外题上

不过，相同的问题重复提交，答案本身也可能变。所以这9组变化，不能全归因于旁边多出的16道题。答案变了，也不一定是退步了，还得看它是改对还是改错。



原论文 Figure 3 · 不同条件与重复作答的结果

JEV · 根据原文回答问题 arXiv:2609.27678v1

06 · 这9组变化，不能全算在额外题上

AI 论文推荐 07 / 07

改对、改错、换错，分开看才清楚

这篇论文把回答一一配对，分开看改对、改错和换成另一种错误。如果你正在研究批量提问，或遇到过“总分没变，具体结果却变了”，这组实验值得一看。

继续阅读原论文

Same Scores, Different Decisions

JEV 与语言模型的阅读理解测试

arxiv.org/abs/2609.27678

JEV · 根据原文回答问题 arXiv:2609.27678v1

07 · 改对、改错、换错，分开看才清楚

JEV评测：题没变，AI却改了答案

JEV这篇评测论文里，有一组专门比较提问安排的实验：同一份合同、同一道题，只在旁边多放16道不用回答的问题，AI会不会改答案？参与这组对照的是Qwen3.5-4B。

A组只展示原题；B组把同一份合同的17道题都展示出来，但也只要求回答原题。两组的问题和正确答案相同，区别在于能不能看见另外16道题。

30道题，每种安排问3次，得到90组配对。Qwen3.5-4B有9组答案变了：4组改对，4组改错，还有1组从一种错答案换成另一种。

改对4组，又改错4组，答对的总数刚好没变。只看准确率，两组似乎一样；回到具体某一道题，拿到的答案却可能不同。

不过，相同的问题重复提交，答案本身也可能变。所以这9组变化，不能全归因于旁边多出的16道题。答案变了，也不一定是退步了，还得看它是改对还是改错。

这篇论文把回答一一配对，分开看改对、改错和换成另一种错误。如果你正在研究批量提问，或遇到过“总分没变，具体结果却变了”，这组实验值得一看。

论文：Same Scores, Different Decisions（JEV与语言模型评测），arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678

#论文推荐 #JEV #大模型评测 #提示词

JEV答题稳不稳？同一题测12次

arXiv:2609.27678v1 [cs.CL] 23 Sep 2026

Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding

Fan Zhang[1,2] Yankai Chen[2,3] Zhuohan Xie[2] Yixi Zhou[4] Sijia Peng[5] Lei Fan[6]
Xinhua Ji[7] Cunyuan Zheng[8] Huangyong Shan[9,11] Philip S. Yu[10] Xue Liu[2,3]
Yu Chen[11] Preslav Nakov[2] Songwei He[9,11]
[1]The University of Tokyo [2]MBZUAI [3]McGill University [4]Hong Kong Baptist University
[5]Fudan University [6]University of Illinois Urbana-Champaign [7]UCloud [8]Columbia University
[9]The University of Hong Kong [10]University of Illinois Chicago [11]Quantell Capital
{fan.zhang, yankai.chen, zhuohan.xie, preslav.nakov}@mbzuai.ac.ae

Abstract

Contract inference requires multiple judgments about a shared document, but aggregate accuracy can conceal changes in the individual decisions. Repeated agreement is also insufficient: a model may consistently return the wrong answer. In this paper, we compare Jev with nine language models on ContractNLI, evaluating inference cost, response time, average correctness, and correctness across repeated request conditions. Controlled comparisons vary hypothesis visibility, requested outputs, and output order while keeping the contract and target judgment fixed. Jev has the lowest cost and median response time among the evaluated configurations, while hosted language models achieve higher baseline accuracy. Rankings by baseline accuracy differ from rankings by correctness across every condition and repeat, although small differences in the latter do not establish a general stability advantage. Development diagnostics further reveal compensating corrections and regressions, as well as persistent errors. These findings motivate evaluating cost and response time alongside whether individual judgments remain correct as the request configuration changes. Code: GitHub.

1 Introduction

Contract review requires several judgments about one document: whether information is confidential, whether copies may be made, and what obligations remain after termination (Koreeda and Manning, 2021; Hendrycks et al., 2021). These judgments can be requested jointly or separately, while their intended answers remain tied to the contract. A model's practical value therefore depends on the cost and time required to obtain its answers and their correctness across request configurations, beyond accuracy in a single configuration.

One difficulty is that aggregate accuracy conceals which judgments change. Behavioral testing examines individual predictions (Ribeiro et al., 2020), while studies of batching, position, demonstration order, and prompt formatting reveal request sensitivity (Lin et al., 2024; Lu et al., 2022; Sclar et al., 2024). A recent preprint likewise shows that similar ranking quality can coexist with different downstream decisions (Frohmann et al., 2026). For judgments sharing one contract, corrections and regressions can cancel each other out even when many decisions differ. Figure 1 (panel 2) illustrates this concern: Qwen3.5-4B changes its prediction for a fixed development-set judgment when more hypotheses become visible, although only the target label is requested.

A second difficulty is that agreement does not establish correctness: a model may repeat an incorrect label across every condition. Variation can also arise when an unchanged request is repeated. Evaluation must therefore score persistent answers against gold labels and use unchanged repetitions as a

01 · 原论文首页

AI 论文推荐 02 / 07

JEV答题稳不稳？同一题测12次

JEV答同一道题，能不能每次都答对？这篇论文挑了30道题，每道问12次。看结果时，要同时留意两件事：答案有没有变，以及答案对不对。

阅读线索

Table 2 · 同一错误反复出现

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

02 · JEV答题稳不稳？同一题测12次

AI 论文推荐 03 / 07

重复问，还得逐次核对答案

这篇论文先让JEV和9个语言模型根据合同内容回答问题，再选30份合同，各固定一道题，换四种提问安排，每种问3次。研究者把每次回答都和正确答案核对。

Controlled request conditions. The stability study fixes one target hypothesis, called the anchor, for each selected test contract. Four conditions preserve its contract and gold label:

A. Only the anchor is visible; only its label is requested.
B. All 17 hypotheses are visible; only the anchor label is requested.
C. The same catalog is visible; all 17 labels are requested, anchor first.
D. The same catalog is visible; all 17 labels are requested, anchor last.

The catalog order is fixed in B/C/D. A–B changes visible hypotheses at a fixed requested answer set; B–C changes output workload and structure at fixed visible content; C–D changes requested output order and structure. Each condition is repeated three times. Primary scoring uses only the fixed anchor; the extra labels in C/D do not increase the number of primary targets.

原论文 §2 · 四种条件，每种重复三次

JEV · 根据原文回答问题 arXiv:2609.27678v1

03 · 重复问，还得逐次核对答案

AI 论文推荐 04 / 07

JEV有5道题，12次都给了同一个错答案

JEV有23道题，12次全部答对；5道题，12次都给了同一个错答案；还有2道题的答案变过。如果只数“回答一样”，那5道一直答错的题也会被算进去。

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	**86.67**	**24/30**	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 · JEV的Same-wrong targets

JEV · 根据原文回答问题 arXiv:2609.27678v1

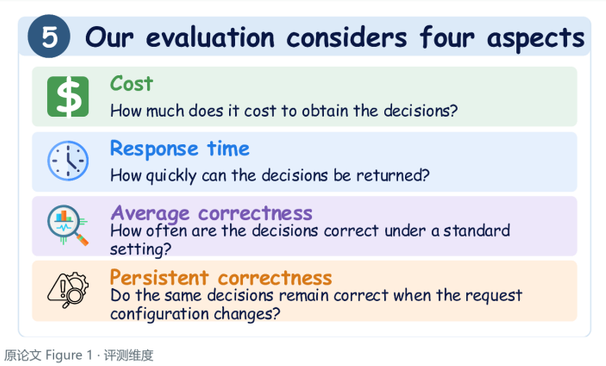
04 · JEV有5道题，12次都给了同一个错答案

JEV答题稳不稳？同一题测12次

AI 论文推荐 05 / 07

答案有没有变，和答案对不对

所以，答案有没有变、答案对不对，要分开看。论文分别记录一直答对、一直答错、答案变过，以及出现过无效回答的题目，避免把“前后一致”当成“判断正确”。



原论文 Figure 1 · 评测维度

JEV · 根据原文回答问题 arXiv:2609.27678v1

05 · 答案有没有变，和答案对不对

AI 论文推荐 06 / 07

这30道题，给了什么启发?

这30道独立题，还不足以估计AI看其他合同会错多少。但评测方法可以借鉴：重复提问之后，别只比较前后答案，还要逐次核对它有没有答对。

阅读线索

§4.2 · 重复测试的范围

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

06 · 这30道题，给了什么启发?

AI 论文推荐 07 / 07

谈模型可靠性，先把“稳定”说清楚

如果你准备让AI反复处理同一类问题，这篇论文提醒我们把“稳定”说清楚：是每次都说一样的话，还是每次都能把问题答对？具体例子在Table 2。

继续阅读原论文

Same Scores, Different Decisions

JEV 与语言模型的阅读理解测试

arxiv.org/abs/2609.27678

JEV · 根据原文回答问题 arXiv:2609.27678v1

07 · 谈模型可靠性，先把“稳定”说清楚

JEV答题稳不稳？同一题测12次

JEV答同一道题，能不能每次都答对？这篇论文挑了30道题，每道问12次。看结果时，要同时留意两件事：答案有没有变，以及答案对不对。

这篇论文先让JEV和9个语言模型根据合同内容回答问题，再选30份合同，各固定一道题，换四种提问安排，每种问3次。研究者把每次回答都和正确答案核对。

JEV有23道题，12次全部答对；5道题，12次都给了同一个错答案；还有2道题的答案变过。如果只数“回答一样”，那5道一直答错的题也会被算进去。

所以，答案有没有变、答案对不对，要分开看。论文分别记录一直答对、一直答错、答案变过，以及出现过无效回答的题目，避免把“前后一致”当成“判断正确”。

这30道独立题，还不足以估计AI看其他合同会错多少。但评测方法可以借鉴：重复提问之后，别只比较前后答案，还要逐次核对它有没有答对。

如果你准备让AI反复处理同一类问题，这篇论文提醒我们把“稳定”说清楚：是每次都说一样的话，还是每次都能把问题答对？具体例子在Table 2。

论文：Same Scores, Different Decisions（JEV与语言模型评测），arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678

#论文推荐 #JEV #AI可靠性 #大模型评测

用 JEV 审批合同，能省多少钱?

arXiv:2609.27678v1 [cs.CL] 23 Sep 2026

Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding

Fan Zhang[1,2] Yankai Chen[2,3] Zhuohan Xie[2] Yixi Zhou[4] Sijia Peng[5] Lei Fan[6]
Xinhua Ji[7] Cunyuan Zheng[8] Huangyong Shan[9,11] Philip S. Yu[10] Xue Liu[2,3]
Yu Chen[11] Preslav Nakov[2] Songwei He[9,11]

[1]The University of Tokyo [2]MBZUAI [3]McGill University [4]Hong Kong Baptist University
[5]Fudan University [6]University of Illinois Urbana-Champaign [7]UCloud [8]Columbia University
[9]The University of Hong Kong [10]University of Illinois Chicago [11]Quantell Capital
{fan.zhang, yankai.chen, zhuohan.xie, preslav.nakov}@mbzuai.ac.ae

Abstract

Contract inference requires multiple judgments about a shared document, but aggregate accuracy can conceal changes in the individual decisions. Repeated agreement is also insufficient: a model may consistently return the wrong answer. In this paper, we compare Jev with nine language models on ContractNLI, evaluating inference cost, response time, average correctness, and correctness across repeated request conditions. Controlled comparisons vary hypothesis visibility, requested outputs, and output order while keeping the contract and target judgment fixed. Jev has the lowest cost and median response time among the evaluated configurations, while hosted language models achieve higher baseline accuracy. Rankings by baseline accuracy differ from rankings by correctness across every condition and repeat, although small differences in the latter do not establish a general stability advantage. Development diagnostics further reveal compensating corrections and regressions, as well as persistent errors. These findings motivate evaluating cost and response time alongside whether individual judgments remain correct as the request configuration changes. Code: GitHub.

1 Introduction

Contract review requires several judgments about one document: whether information is confidential, whether copies may be made, and what obligations remain after termination (Koreeda and Manning, 2021; Hendrycks et al., 2021). These judgments can be requested jointly or separately, while their intended answers remain tied to the contract. A model's practical value therefore depends on the cost and time required to obtain its answers and their correctness across request configurations, beyond accuracy in a single configuration.

One difficulty is that aggregate accuracy conceals which judgments change. Behavioral testing examines individual predictions (Ribeiro et al., 2020), while studies of batching, position, demonstration order, and prompt formatting reveal request sensitivity (Lin et al., 2024; Lu et al., 2022; Sclar et al., 2024). A recent preprint likewise shows that similar ranking quality can coexist with different downstream decisions (Frohmann et al., 2026). For judgments sharing one contract, corrections and regressions can cancel each other out even when many decisions differ. Figure 1 (panel 2) illustrates this concern: Qwen3.5-4B changes its prediction for a fixed development-set judgment when more hypotheses become visible, although only the target label is requested.

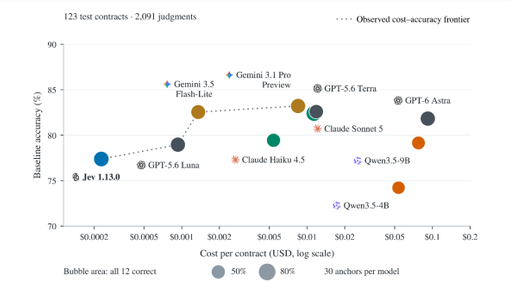
A second difficulty is that agreement does not establish correctness: a model may repeat an incorrect label across every condition. Variation can also arise when an unchanged request is repeated. Evaluation must therefore score persistent answers against gold labels and use unchanged repetitions as a

01 · 原论文首页

AI 论文推荐 02 / 07

用 JEV 审批合同，能省多少钱?

把JEV用在合同审批前的条款核对，费用怎么样？这篇论文让它和9个语言模型根据合同内容回答问题，记录了每份合同的费用、响应时间和准确率，可以放在一起比较。



原论文 Figure 2 · 成本与准确率

JEV · 根据原文回答问题 arXiv:2609.27678v1

02 · 用 JEV 审批合同，能省多少钱?

AI 论文推荐 03 / 07

这套配置下，JEV成本约为六分之一

这篇论文比较了JEV和9个语言模型。在123份合同、2091道问题的基础测试中，JEV每份合同花费0.000228美元，Gemini 3.5 Flash-Lite为0.001353美元。按论文的配置和价格算，JEV约为后者的六分之一。

Model	Accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev 1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini 3.5 Flash-Lite	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini 3.1 Pro Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6 Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6 Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6 Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude Haiku 4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude Sonnet 5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

原论文 Table 1 · 每份合同的成本

JEV · 根据原文回答问题 arXiv:2609.27678v1

03 · 这套配置下，JEV成本约为六分之一

AI 论文推荐 04 / 07

成本低，准确率也有取舍

但便宜也有取舍。JEV的基础准确率是77.38%，Flash-Lite是82.54%，高5.16个百分点。两者响应时间的中位数，分别为1.24秒和1.60秒。

Model	Accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev 1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini 3.5 Flash-Lite	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini 3.1 Pro Preview	**83.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6 Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6 Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6 Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude Haiku 4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude Sonnet 5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

原论文 Table 1 · 基础准确率与响应时间

JEV · 根据原文回答问题 arXiv:2609.27678v1

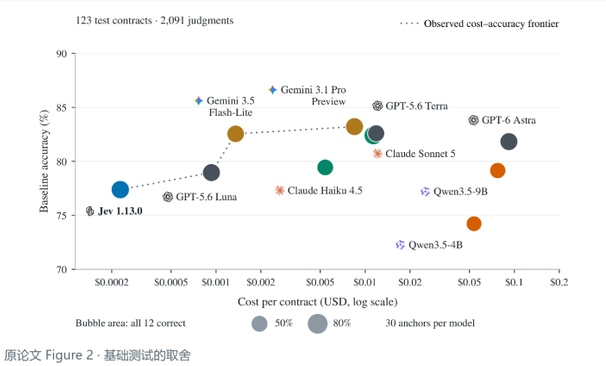
04 · 成本低，准确率也有取舍

用 JEV 审批合同，能省多少钱?

AI 论文推荐 05 / 07

把价格、速度、准确率放在一起看

这套配置下，JEV花得少、返回得快；Flash-Lite答对得更多。论文把这几项放在一起，让人更容易比较：愿意多花的钱，换来了多少正确回答。



原论文 Figure 2 · 基础测试的取舍

JEV · 根据原文回答问题 arXiv:2609.27678v1

05 · 把价格、速度、准确率放在一起看

AI 论文推荐 06 / 07

两组测试的分数，不能混着比较

论文还单独挑了30道题，换提问安排、反复作答，观察哪些题能一直答对。那组分数和这里的基础准确率，用的题目和统计方式不同，要分开看。

阅读线索

Table 1与Table 2 · 样本与计算方式不同

完整文案与论文链接见发布正文

JEV · 根据原文回答问题 arXiv:2609.27678v1

06 · 两组测试的分数，不能混着比较

AI 论文推荐 07 / 07

做模型选型，可以先看Table 1

这些数字对应论文测试时的版本、配置和价格。如果你在挑选处理文档的AI，可以先看Table 1里的成本和准确率，再看Table 2里的重复作答记录，想想哪种表现更符合自己的需要。

继续阅读原论文

Same Scores, Different Decisions

JEV 与语言模型的阅读理解测试

arxiv.org/abs/2609.27678

JEV · 根据原文回答问题 arXiv:2609.27678v1

07 · 做模型选型，可以先看Table 1

用 JEV 审批合同，能省多少钱?

把JEV用在合同审批前的条款核对，费用怎么样？这篇论文让它和9个语言模型根据合同内容回答问题，记录了每份合同的费用、响应时间和准确率，可以放在一起比较。

这篇论文比较了JEV和9个语言模型。在123份合同、2091道问题的基础测试中，JEV每份合同花费0.000228美元，Gemini 3.5 Flash-Lite为0.001353美元。按论文的配置和价格算，JEV约为后者的六分之一。

但便宜也有取舍。JEV的基础准确率是77.38%，Flash-Lite是82.54%，高5.16个百分点。两者响应时间的中位数，分别为1.24秒和1.60秒。

这套配置下，JEV花得少、返回得快；Flash-Lite答对得更多。论文把这几项放在一起，让人更容易比较：愿意多花的钱，换来了多少正确回答。

论文还单独挑了30道题，换提问安排、反复作答，观察哪些题能一直答对。那组分数和这里的基础准确率，用的题目和统计方式不同，要分开看。

这些数字对应论文测试时的版本、配置和价格。如果你在挑选处理文档的AI，可以先看Table 1里的成本和准确率，再看Table 2里的重复作答记录，想想哪种表现更符合自己的需要。

论文：Same Scores, Different Decisions（JEV与语言模型评测），arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678

#论文推荐 #JEV #AI应用 #大模型评测

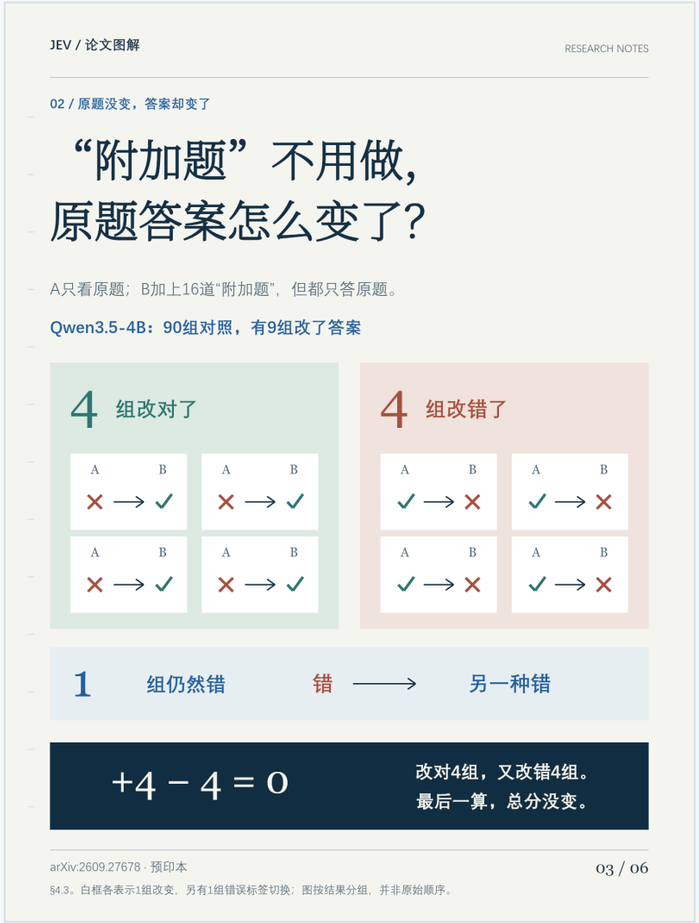
让AI处理合同，JEV表现如何?



01 · 让AI处理合同，JEV表现如何?

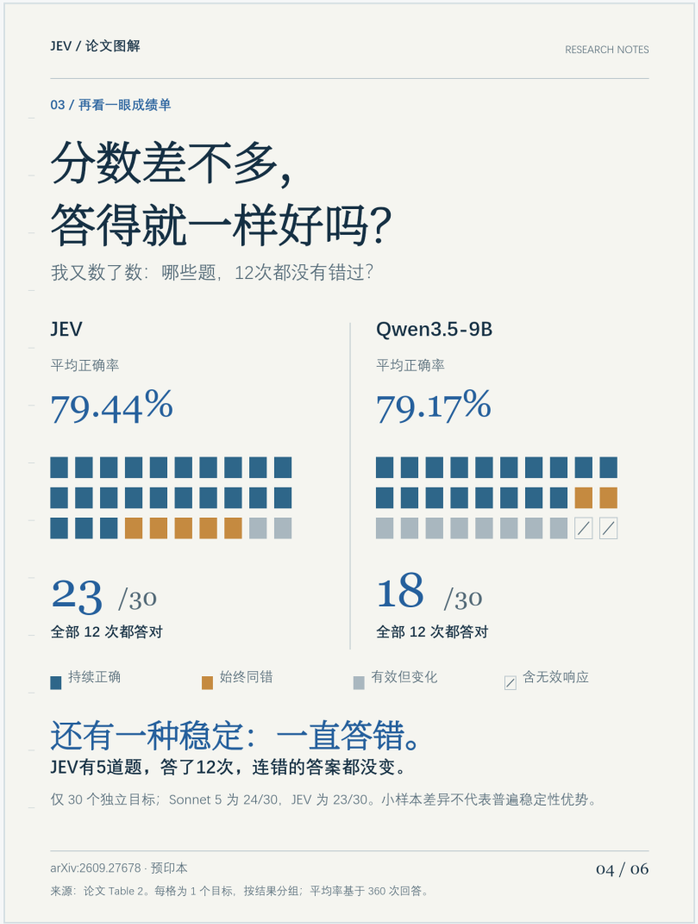


02 · JEV和9个模型，回答了同一批问题。



03 · 附加题不用做，原题答案怎么变了?

让AI处理合同，JEV表现如何?



04 · 分数差不多，答得就一样好吗?



05 · 确实省了钱，那准确率呢?



06 · 看完之后，我不会只盯着总分。

让AI处理合同，JEV表现如何?

我最近读到一篇论文，用123份合同来测AI：给它原文，再问里面是怎么规定的。除了答对多少，还看要花多少钱、回答会不会变。

基础测试里，JEV每份合同花费0.000228美元，响应时间中位数为1.24秒。Flash-Lite约花6倍的钱，准确率为82.54%，比JEV的77.38%高5.16个百分点。便宜和快都看得到，准确率也要一起看。

研究者让JEV和9个语言模型回答123份合同里的2091道问题，再从中挑30份合同，各固定一道题，换四种提问安排，每种问3次。原文、问题和正确答案不变，一道题共得到12个回答。

在30道题的重复测试中，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，分别有23道和18道。JEV也有5道题，12次都给了同一个错答案。

还有一组对照：让Qwen3.5-4B多看16道题，但仍只回答原题。90组配对里，有9组答案变了：4组改对、4组改错、1组换了个错答案。答对的总数刚好没变。相同请求重复提交也可能改变答案，不能把这些变化全算在额外题目上。

读完以后，我更想翻一翻具体的错题。总分接近的模型，不一定在同样的题上靠谱；前后说得一样，也不一定说得对。

我把结果整理成了6张图，最后一张列了接着读论文的线索。结果对应本次任务和配置；重复测试只有30道独立题，不能据此判断所有场景里的表现。

论文：Same Scores, Different Decisions，Fan Zhang等，
arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#论文解读 #JEV #AI评测 #大模型 #阅读理解

JEV便宜这么多，答题靠谱吗?



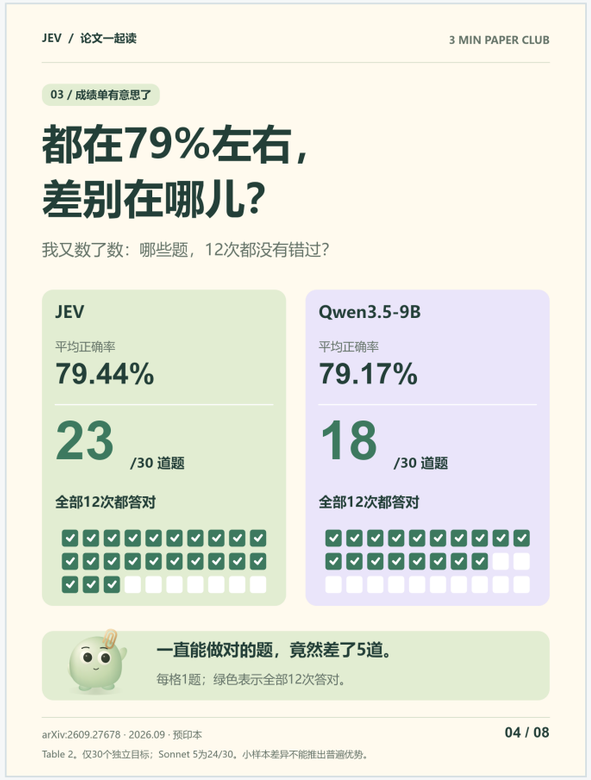
01 · JEV便宜这么多，答题靠谱吗?



02 · 先试一题：这些资料能直接复制吗?



03 · JEV和9个模型，回答了同一批问题。



04 · 都在79%左右，差别在哪儿?

JEV便宜这么多，答题靠谱吗?



05 · AI也可能“稳定地答错”。



06 · 附加题不用做，原题答案怎么变了?



07 · 便宜是真的，答题水平也得看。



08 · 选用AI之前，我会问这三件事。

JEV便宜这么多，答题靠谱吗？

这篇论文里，JEV每份合同的花费约为Flash-Lite的六分之一。价格挺有吸引力，但它到底答得怎么样？先看论文里的一道例题。

合同里写着：复制保密资料前，必须先取得书面同意。那“只在公司内部用，就可以直接复制”对吗？不对，内部使用也得先拿到同意。这次测试考的，就是AI能不能根据原文答对这类问题。

研究者让JEV和9个语言模型回答123份合同里的2091道问题，再从中挑30份合同，各固定一道题，换四种提问安排，每种问3次。原文、问题和正确答案不变，一道题共得到12个回答。

在30道题的重复测试中，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，分别有23道和18道。JEV也有5道题，12次都给了同一个错答案。

还有一组对照：让Qwen3.5-4B多看16道题，但仍只回答原题。90组配对里，有9组答案变了：4组改对、4组改错、1组换了个错答案。答对的总数刚好没变。相同请求重复提交也可能改变答案，不能把这些变化全算在额外题目上。

基础测试里，JEV每份合同花费0.000228美元，响应时间中位数为1.24秒。Flash-Lite约花6倍的钱，准确率为82.54%，比JEV的77.38%高5.16个百分点。便宜和快都看得到，准确率也要一起看。

把这些放在一起，我会多问三件事：答对了多少？哪些题能一直答对？要花多少钱、等多久？8张图和最后一页的阅读提示，按这个顺序讲清楚。

例题为论文Figure 1的中文转述。基础测试与重复测试分开统计；结果只对应所测任务、配置和计价方式。30道独立题不足以代表普遍表现。

论文：Same Scores, Different Decisions，Fan Zhang等，
arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#论文解读 #JEV #AI评测 #大模型 #阅读理解

AI做题，又快又准……吗?

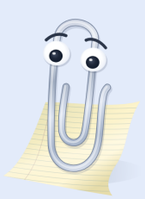
JEV / 论文一起读 3 MIN PAPER CLUB

3分钟，看懂这次AI测试

AI做题，又快又准…… 吗?

我带你看看，JEV和其他模型做得怎么样。

JEV
TypeSafe
79.44%
平均正确率



Qwen
3.5-9B
79.17%
平均正确率

不只比谁答得快，也看看谁容易答错。

arXiv:2609.27678 · 2026.09 · 预印本 01 / 08

两侧分数：Table 2，同一30个目标、各12次回答。成本与速度另见基础测试。

01 · AI做题，又快又准……吗?

JEV / 论文一起读 3 MIN PAPER CLUB

01 / 先试试，你会怎么选

先别看分数，这些资料能复制吗?

论文里的例题 · 中文转述

未经披露方事先书面同意，不得复制、复现或分发保密信息。

那下面这句话，能成立吗?

“接收方可以为内部使用，复制保密信息。”

和原文一致 | 和原文不符 | 原文没提到



这句话，和原文的规定不符。

只在公司内部用，也得先取得书面同意。

arXiv:2609.27678 · 2026.09 · 预印本 02 / 08

依据论文 Figure 1 中文意译；题目nda-2。该图为说明性转述，不是合同原文逐字摘录。

02 · 先试一题：这些资料能直接复制吗?

JEV / 论文一起读 3 MIN PAPER CLUB

02 / 好，把题交给AI

JEV和9个模型，回答了同一批问题。

考完一遍还不够，研究者又给它们加了点难度。

123
份合同

2,091
道问题

接着，挑出30份合同，每份固定一道题：

4 种问法
加题、合问或调整顺序

×

3 次重复
每种方式都问3次

=

12 次回答 / 题
检查每次是否答对



一题问12次，一次都不能错。

论文把这种表现叫作“持续正确”。

arXiv:2609.27678 · 2026.09 · 预印本 03 / 08

§2–3。30个独立合同目标；重复回答不增加独立合同数。任务为ContractNLI分类。

03 · JEV和9个模型，回答了同一批问题。

JEV / 论文一起读 3 MIN PAPER CLUB

03 / 成绩单有意思了

都在79%左右，差别在哪儿?

我又数了数：哪些题，12次都没有错过?

JEV
平均正确率
79.44%
23 /30 道题
全部12次都答对

Qwen3.5-9B
平均正确率
79.17%
18 /30 道题
全部12次都答对



一直能做对的题，竟然差了5道。

每格1题；绿色表示全部12次答对。

arXiv:2609.27678 · 2026.09 · 预印本 04 / 08

Table 2。仅30个独立目标；Sonnet 5为24/30。小样本差异不能推出普遍优势。

04 · 都在79%左右，差别在哪儿?

AI做题，又快又准……吗?



05 · AI也可能“稳定地答错”。



06 · 附加题不用做，原题答案怎么变了?



07 · 便宜是真的，答题水平也得看。



08 · 选用AI之前，我会问这三件事。

AI做题，又快又准……吗?

先别看模型排行榜，试试这道题。

合同里写着：复制保密资料前，必须先取得书面同意。那“只在公司内部用，就可以直接复制”对吗？不对，内部使用也得先拿到同意。这次测试考的，就是AI能不能根据原文答对这类问题。

人看起来不难，那交给AI呢？这篇论文把JEV和另外9个语言模型放到一起比较。

研究者让JEV和9个语言模型回答123份合同里的2091道问题，再从中挑30份合同，各固定一道题，换四种提问安排，每种问3次。原文、问题和正确答案不变，一道题共得到12个回答。

在30道题的重复测试中，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，分别有23道和18道。JEV也有5道题，12次都给了同一个错答案。

“稳定地答错”这件事挺值得琢磨：问多少次都一样，未必是好消息，还得看它有没有答对。

还有一组对照：让Qwen3.5-4B多看16道题，但仍只回答原题。90组配对里，有9组答案变了：4组改对、4组改错、1组换了个错答案。答对的总数刚好没变。相同请求重复提交也可能改变答案，不能把这些变化全算在额外题目上。

基础测试里，JEV每份合同花费0.000228美元，响应时间中位数为1.24秒。Flash-Lite约花6倍的钱，准确率为82.54%，比JEV的77.38%高5.16个百分点。便宜和快都看得到，准确率也要一起看。

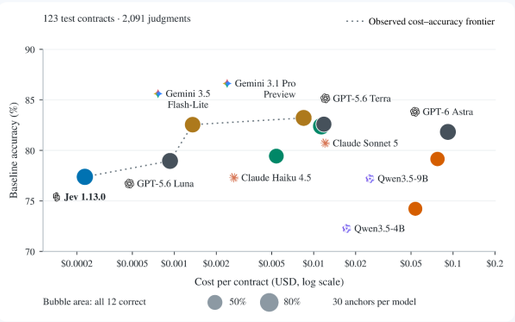
8张图里，我把这些结果串在一起。最后一张留了Table 1和Table 2的阅读提示。例题为论文图1中文转述；结果限于所测任务和配置，重复测试只有30道独立题。

论文：Same Scores, Different Decisions，Fan Zhang等，
arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#论文解读 #JEV #AI评测 #大模型 #阅读理解

JEV对比9个大模型，结果如何?

JEV / AI论文解读 原论文图表 · 中文讲解



原论文 Figure 2 / 123份合同的成本、准确率与持续正确性

AI论文解读

JEV对比9个大模型，结果如何?

研究者换了4种提问安排，每种测3次。

看同一道题，还能不能一直答对。

图表直接摘自论文PDF；坐标为基础测试，气泡面积为30题中12次全对的比例。

01 · JEV对比9个大模型，结果如何?

JEV / AI论文解读 Figure 1 / 先看一道例题

这些资料，能直接复制吗?

Non-Disclosure Agreement (excerpt)

1 This Non-Disclosure Agreement ("Agreement") is made between the Disclosing
2 Party and the Receiving Party (each a "Party").
3 2. Confidential Information. The Receiving Party shall keep all Confidential
4 Information in strict confidence and shall not use such information except
5 for the purpose of evaluating a potential business relationship.
6 3. No Copying. The Receiving Party shall not copy, reproduce, or distribute
7 any Confidential Information, in whole or in part, by any means, without the
8 prior written consent of the Disclosing Party.
9 ...
10 6. Return or Destruction. Upon termination or expiration of this Agreement,
11 the Receiving Party shall promptly return to the Disclosing Party, or destroy,
12 all copies of the Confidential Information in its possession, including any
13 materials derived therefrom.

原论文 Figure 1 局部 / 例题中的原文

图中第6—8行说的是：

未经事先书面同意，
不得复制保密信息。

如果只在公司内部用，能直接复制吗?

这道示例题，答案是“和原文不符”。
公司内部使用，也得先取得书面同意。

Figure 1（1）、§2 · 原图保留；中文为意译，条款为说明性示例。

02 · 这些资料能直接复制吗？AI得看懂原文。

JEV / AI论文解读 Figure 3 / 实验怎么做

同一道题，研究者做了12次测试

Official test · 30 contract anchors · 3 repeats per condition

	Across conditions A→B	B→C	C→D	Repeated identical requests A	B	C	D
Jev 1.13.0	4/90	1/90	0/90	0/90	2/90	0/90	0/90
Gemini 3.5 Flash-Lite	7/90	3/90	6/90	2/90	0/90	4/90	0/90
Gemini 3.1 Pro Preview	7/89	7/90	3/90	4/88	2/90	4/90	0/90
GPT-5.6 Luna	8/90	8/90	11/90	0/90	2/90	2/90	2/90
GPT-5.6 Terra	7/90	7/90	10/90	6/90	6/90	5/90	8/90
GPT-6 Astra	4/90	3/90	3/90	4/90	2/90	2/90	2/90
Claude Haiku 4.5	8/90	6/90	14/90	2/90	6/90	2/90	6/90
Claude Sonnet 5	5/90	6/90	3/90	0/90	2/90	2/90	2/90
Qwen3.5-4B	9/90	9/88	14/87	10/90	10/90	6/86	13/88
Qwen3.5-9B	15/90	7/90	12/88	12/90	6/90	8/90	11/86

0 5 10 15 20
Changed labels among jointly valid pairs (%)

Cells: changed / jointly valid pairs, out of 90 planned pairs in every cell.

原论文 Figure 3 / 左侧比较安排变化，右侧比较相同请求的重复

固定30道题，每种安排各问3次。

A 单独看，只答原题
B 全部看，只答原题
C 全部答，原题先答
D 全部答，原题后答

原文、要回答的问题和正确答案都不变。

§2、§3.1、Figure 3 · 四种安排×3次 = 12次；热图记录标签变化，不等同于变差。

03 · 同一道题，研究者做了12次测试

JEV / AI论文解读 Table 2 / 看平均分，也看每道题

平均分接近，一直答对的题却不同

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	86.67	24/30	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 / 30个目标、4种安排、每种重复3次

青框看这两列：平均正确率 / 12次全对

JEV

79.44%

12次全部答对

23 / 30道

Qwen3.5-9B

79.17%

12次全部答对

18 / 30道

只有30道独立题，还不能据此认定JEV普遍更稳。

Table 2、§4.2 · 青框为本稿阅读标注；均值接近不构成统计等效证明。

04 · 平均分接近，一直答对的题却不同

JEV对比9个大模型，结果如何?

JEV / AI论文解读 Table 2 / 再看同一张表的错题

JEV有5道题，12次都答错

Model	Mean correct (%) ↑	All 12 correct ↑	Same wrong	Changed valid	Any invalid
Jev 1.13.0	79.44	23/30	5	2	0
Gemini 3.5 Flash-Lite	82.50	21/30	4	5	0
Gemini 3.1 Pro Preview	85.28	22/30	2	5	1
GPT-5.6 Luna	81.94	22/30	3	5	0
GPT-5.6 Terra	80.56	20/30	2	8	0
GPT-6 Astra	76.39	22/30	6	2	0
Claude Haiku 4.5	81.94	19/30	2	9	0
Claude Sonnet 5	**86.67**	**24/30**	1	5	0
Qwen3.5-4B	77.50	17/30	2	8	3
Qwen3.5-9B	79.17	18/30	2	8	2

原论文 Table 2 / 这次看 Same wrong（始终同错）一列

5道题

每次都是同一个错答案

表里还有2道题，12次的有效答案发生变化。

看它每次回答是否相同还不够，
还得逐题对照标准答案。

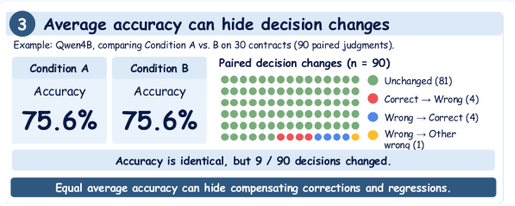
arXiv:2609.27678v1 · 预印本 05 / 08

Table 2、§4.2 · 赭红框为本稿标注；四类结果互斥，每个模型合计30道题。

05 · JEV有5道题，12次都答错

JEV / AI论文解读 Figure 1 / 总分没说完的事

总分没变，9组答案却变了



原论文 Figure 1 第3部分 / Qwen3.5-4B 正式测试A与B

多看另外16道题，仍然只答原题。
90组前后对照里，9组答案发生变化。

4组 错 → 对

4组 对 → 错

1组 错 → 另一个错

改对4组，又改错4组，答对的总数刚好没变。

90组 = 30道题×3次配对。

arXiv:2609.27678v1 · 预印本 06 / 08

Figure 1（3）、§4.3 · 原图保留；9组变化不等于9道独立题。

06 · 总分没变，9组答案却变了

JEV / AI论文解读 Table 1 / 成本与准确率

JEV花得少，Flash-Lite答对得更多

Model	Accuracy (%) ↑	95% interval	Macro-F1 (%) ↑	Cost (USD/contract) ↓	Median time (s) ↓	Valid calls
Jev 1.13.0	77.38	[75.99, 78.81]	72.23	**0.000228**	**1.24**	123/123
Gemini 3.5 Flash-Lite	82.54	[81.11, 83.98]	76.96	0.001353	1.60	123/123
Gemini 3.1 Pro Preview	**85.21**	[81.68, 84.79]	**77.71**	0.008474	3.73	123/123
GPT-5.6 Luna	78.96	[77.19, 80.63]	73.77	0.000931	1.74	123/123
GPT-5.6 Terra	82.59	[81.16, 84.03]	77.23	0.011839	11.61	123/123
GPT-6 Astra	81.83	[80.20, 83.36]	76.55	0.091890	20.94	123/123
Claude Haiku 4.5	79.44	[77.81, 81.11]	74.46	0.005396	5.65	123/123
Claude Sonnet 5	82.40	[80.97, 83.84]	76.38	0.011352	3.27	123/123
Qwen3.5-4B	74.22	[70.59, 77.38]	71.67	0.053653	86.87	117/123
Qwen3.5-9B	79.15	[76.81, 81.21]	74.57	0.077361	134.64	122/123

原论文 Table 1 / 123份合同、2091项判断的基础测试

看前两行：JEV / Gemini 3.5 Flash-Lite

0.000228 → 0.001353

美元 / 合同，Flash-Lite成本约为JEV的6倍。

77.38% → 82.54%

基础准确率高5.16个百分点。

费用与时间只对应论文所测配置。

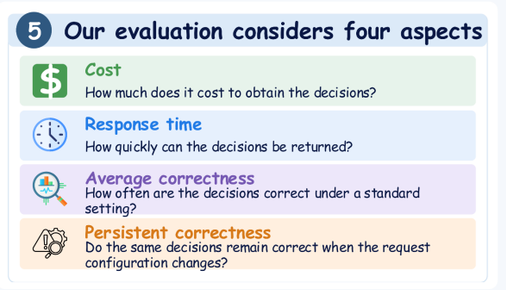
arXiv:2609.27678v1 · 预印本 07 / 08

Table 1、§3.3 · 青框为本稿标注；表中时间为客户端响应时间。

07 · JEV花得少，Flash-Lite答对得更多

JEV / AI论文解读 Figure 1 / 读完之后

读完这篇，我会多看一眼错题



原论文 Figure 1 第5部分 / 评测同时考虑的四件事

看完总分，再看看每道题的回答。

哪些一直答对，哪些反复答错，哪些换个问法就变了。

回到论文里核对

Table 1 看费用与准确率；Table 2 看每道题的回答。

arxiv.org/abs/2609.27678

arXiv:2609.27678v1 · 预印本 08 / 08

Fan Zhang等 · 2026.09.23 · 重复测试仅30道独立题；论文与代码链接见发布文案。

08 · 读完这篇，我会多看一眼错题

JEV对比9个大模型，结果如何?

把合同交给AI，再问它里面是怎么规定的。第一次答对了，换一种提问安排，它还能答对吗？这篇论文把同一道题反复测了12次。

研究者让JEV和9个语言模型回答123份合同里的2091道问题，再从中挑30份合同，各固定一道题，换四种提问安排，每种问3次。原文、问题和正确答案不变，一道题共得到12个回答。

在30道题的重复测试中，JEV和Qwen3.5-9B的平均正确率都约79%。但12次全部答对的题，分别有23道和18道。JEV也有5道题，12次都给了同一个错答案。

还有一组对照：让Qwen3.5-4B多看16道题，但仍只回答原题。90组配对里，有9组答案变了：4组改对、4组改错、1组换了个错答案。答对的总数刚好没变。相同请求重复提交也可能改变答案，不能把这些变化全算在额外题目上。

基础测试里，JEV每份合同花费0.000228美元，响应时间中位数为1.24秒。Flash-Lite约花6倍的钱，准确率为82.54%，比JEV的77.38%高5.16个百分点。便宜和快都看得到，准确率也要一起看。

比起再看一个总分，我更想看这些具体记录：哪些题一直对，哪些反复错，哪些换个安排就变了。图里直接引用论文的原图、原表，方便对照着读。

重复测试只有30道独立题，还不能说明哪个模型在所有场景里更稳。这里测的是根据原文回答问题，也没有验证AI能否找全合同里的法律风险。

论文：Same Scores, Different Decisions，Fan Zhang等，
arXiv:2609.27678v1，预印本。
https://arxiv.org/abs/2609.27678
代码：https://github.com/ZF-Utokyo/Jev-Benchmark

#论文解读 #JEV #AI评测 #大模型 #阅读理解